

Федеральное государственное образовательное бюджетное учреждение
высшего образования
«Финансовый университет при Правительстве Российской Федерации»
(Финансовый университет)
Факультет информационных технологий и анализа больших данных
Кафедра искусственного интеллекта

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

на тему:

**«Оптимизация процесса автоматической классификации
инвестиционных рисков путем объединения деревьев решений и
кластеризационного анализа с использованием искусственных нейронных
сетей»**

Направление подготовки 01.03.02 - Прикладная математика и
информатика

Образовательная программа «Прикладное машинное обучение»

Выполнил:

студент 4 курса, ПМ22-2 учебной группы

_____ Поддуба И. С.

Научный руководитель:

Москва - 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	
ГЛАВА 1. ПОСТАНОВКА ЗАДАЧИ АВТОМАТИЧЕСКОЙ КЛАССИФИКАЦИИ ИНВЕСТИЦИОННЫХ РИСКОВ	
1.1. Экономическая сущность инвестиционного риска	
1.2. Ручной и экспертный подход к классификации инвестиционных рисков	
1.3. Ограничения ручного анализа и необходимость автоматизации	
1.4. Формальная постановка задачи исследования	
1.5. Критерии оценки оптимизации процесса классификации	
1.6. Границы исследования и основные допущения	
ГЛАВА 2. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ КЛАССИФИКАЦИИ ИНВЕСТИЦИОННЫХ РИСКОВ	
2.1. Анализ инвестиционного риска как объекта классификации	
2.2. Анализ исходных данных для оценки инвестиционных рисков	
2.3. Анализ экономических и математических показателей инвестиционного риска	
2.4. Анализ применимости методов машинного обучения к задаче классификации риска	
2.5. Обоснование целевой переменной и признакового пространства	
2.6. Протокол проверки качества и предотвращение утечки данных	
2.7. Связь экономических показателей с признаками модели	
2.8. Обоснование гибридной архитектуры классификации	
ГЛАВА 3. РЕАЛИЗАЦИЯ ML-ПАЙПЛАЙНА И ОЦЕНКА РЕЗУЛЬТАТОВ	
3.1. Архитектура разработанного ML- пайплайна	

3.2. Реализация расчета признаков и целевой переменной	
3.3. Реализация моделей машинного обучения	
3.4. Оценка качества и интерпретация результатов	
3.5. Оценка масштабируемости и воспроизводимости процесса	
3.6. Ограничения реализации и направления развития	
3.7. Экономическая интерпретация результатов классификации	
3.8. Последовательность применения разработанного процесса	
ЗАКЛЮЧЕНИЕ	
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	

ВВЕДЕНИЕ

Инвестиционный риск является одной из центральных категорий финансового анализа, поскольку именно риск определяет границы допустимого выбора активов, требования к ожидаемой доходности и устойчивость портфеля к неблагоприятным рыночным условиям. На рынке акций риск проявляется не только через изменчивость цены, но и через глубину просадки, вероятность хвостовых потерь, снижение ликвидности и ухудшение фундаментального состояния эмитента. Поэтому задача классификации инвестиционного риска не может сводиться к одной простой метрике и требует системного рассмотрения.

Актуальность темы связана с ростом объема финансовых данных и усложнением структуры факторов, влияющих на риск акций. Аналитику необходимо учитывать рыночные цены, объемы торгов, макроэкономические показатели, финансовую отчетность эмитентов, секторную принадлежность и режим рынка. При ручной обработке такой массив информации становится трудно масштабируемым: чем больше объектов, периодов и признаков рассматривается, тем выше вероятность субъективных решений и технических ошибок при расчете показателей.

Ручной и экспертный анализ остается важным элементом инвестиционного процесса, однако его ограничения особенно заметны при регулярной классификации большого числа активов. Эксперт может интерпретировать одни и те же показатели по-разному в зависимости от опыта, выбранных нормативов и текущего рыночного контекста. Кроме того, ручной подход затрудняет воспроизводимость: повторить прежний результат без полного журнала расчетов, версий данных и правил принятия решений становится проблематично.

В этих условиях возникает необходимость формализовать процесс классификации инвестиционных рисков и представить его как воспроизводимый ML-пайплайн. Такой пайплайн должен не просто обучать модель, а последовательно решать задачи сбора данных, подготовки признаков, формирования целевой переменной, временного разделения выборки, обучения

моделей, оценки качества и контроля устойчивости результата. Только при такой постановке автоматизация становится предметом исследования, а не отдельным техническим запуском.

Тема выпускной квалификационной работы сформулирована как оптимизация процесса автоматической классификации инвестиционных рисков путем объединения деревьев решений и кластеризационного анализа с использованием искусственных нейронных сетей. В рамках данной формулировки под оптимизацией понимается не только повышение значения одной метрики качества, но и построение более формализованного, масштабируемого и воспроизводимого процесса классификации.

Объектом исследования является процесс классификации инвестиционных рисков на основе финансовых, рыночных и иных аналитических данных. Предметом исследования являются методы автоматизации и оптимизации классификации инвестиционных рисков путем объединения деревьев решений, кластеризационного анализа и искусственных нейронных сетей в единый ML-пайплайн.

Цель исследования - разработка и оценка процесса автоматической классификации инвестиционных рисков путем объединения деревьев решений и кластеризационного анализа с использованием искусственных нейронных сетей.

Для достижения поставленной цели необходимо решить следующие задачи: изучить существующие подходы к оценке и классификации инвестиционных рисков; проанализировать ограничения ручного и экспертного подхода; определить признаки и метрики, необходимые для формализации задачи; спроектировать ML-пайплайн, объединяющий деревья решений, кластеризационный анализ и искусственные нейронные сети; реализовать модели машинного обучения; оценить качество разработанного подхода и сравнить его с базовым методом классификации.

Методологическую основу исследования составляют методы финансового анализа, статистики временных рядов, feature engineering,

supervised learning, кластеризационного анализа, нейросетевого извлечения латентных факторов и оценки качества классификации. В работе используются метрики риска, отражающие доходность, волатильность, максимальную просадку, downside-volatility, CVaR, ликвидность и рыночную чувствительность.

Информационную основу работы составляют данные по акциям российских эмитентов, обращающимся на Московской бирже, данные рыночного индекса, макроэкономические показатели и признаки, извлеченные из финансовой отчетности. Программная реализация выполнена на Python с использованием pandas, NumPy, scikit-learn и PyTorch для слоя латентных факторов. Валидация строится по временной схеме, что принципиально важно для финансовых данных.

Практическая значимость работы заключается в разработке воспроизводимого программного прототипа, который может использоваться как основа системы риск-скоринга акций. Теоретическая значимость состоит в систематизации признаков инвестиционного риска и в обосновании гибридной архитектуры, объединяющей интерпретируемые деревья решений, кластеризацию рыночных режимов и нейросетевое извлечение скрытых факторов.

Работа состоит из введения, трех глав, заключения и списка использованных источников. В первой главе формулируется задача и обосновывается актуальность автоматизации. Во второй главе проводится анализ предметной области, данных, формул и методов. В третьей главе описывается реализация ML-пайплайна и оцениваются полученные результаты.

ГЛАВА 1. ПОСТАНОВКА ЗАДАЧИ АВТОМАТИЧЕСКОЙ КЛАССИФИКАЦИИ ИНВЕСТИЦИОННЫХ РИСКОВ

1.1. Экономическая сущность инвестиционного риска

Инвестиционный риск в широком смысле представляет собой возможность отклонения фактического результата инвестирования от ожидаемого. Для акций такое отклонение выражается в изменении цены, снижении дивидендной привлекательности, ухудшении ликвидности и изменении финансового состояния эмитента. В прикладном риск-анализе важно рассматривать риск не только как волатильность, но и как вероятность значимых потерь в будущем периоде.

Традиционная трактовка риска через дисперсию доходности удобна математически, но в инвестиционных решениях она часто оказывается неполной. Актив с умеренной средней волатильностью может иметь редкие, но глубокие просадки, а актив с высокой краткосрочной волатильностью может оставаться ликвидным и быстро восстанавливаться. Поэтому для классификации риска необходимо учитывать несколько измерений: изменчивость, глубину падения, хвостовые потери и возможность выхода из позиции.

Для рынка акций характерна зависимость риска от внешних и внутренних факторов. Внешние факторы включают процентные ставки, валютный курс, рыночную волатильность, состояние ликвидности и общую корреляцию между бумагами. Внутренние факторы связаны с долговой нагрузкой эмитента, устойчивостью денежных потоков, маржинальностью бизнеса и качеством раскрытия отчетности. Совокупность этих факторов формирует риск-профиль актива.

Экономически риск акции удобно представить как взаимодействие шока, чувствительности к шоку и внутренней хрупкости эмитента. Рыночный шок может быть вызван изменением ставки, валютным движением или падением индекса. Чувствительность выражается через β , волатильность и корреляцию

с рынком. Хрупкость определяется финансовыми коэффициентами, ликвидностью торгов и способностью компании обслуживать обязательства.

Классификация инвестиционного риска отличается от задачи точного прогнозирования цены. В работе требуется не предсказать будущую стоимость акции, а отнести наблюдение к одному из классов риска. Такая постановка ближе к практическому риск-менеджменту, где решение часто формулируется как допустимый, повышенный или высокий уровень риска. Категориальный результат проще интерпретировать и использовать в последующих правилах отбора активов.

Использование классов low, medium и high позволяет согласовать модель машинного обучения с экономическим смыслом риск-оценки. Класс low означает относительно благоприятный профиль по будущим компонентам риска, medium отражает промежуточное состояние, а high сигнализирует о повышенной вероятности неблагоприятной реализации. При этом классы не задаются произвольно: они должны быть получены на основе формализованных компонент будущего риска.

Важным свойством задачи является ее временная направленность. Признаки на дату решения должны описывать только доступное на тот момент состояние, а целевая переменная формируется по будущему окну. Если данные будущего периода попадут в признаки, модель покажет завышенное качество и потеряет прикладной смысл. Поэтому задача классификации инвестиционного риска требует point-in-time архитектуры данных.

Для дипломной работы ключевой является связка между экономической сущностью риска и машинным обучением. Нельзя ограничиться описанием алгоритмов без объяснения того, какие финансовые свойства они должны отражать. Поэтому в работе риск рассматривается как многокомпонентная характеристика, а модели используются как инструмент автоматизации ее классификации.

Такой подход позволяет избежать распространенной ошибки, когда модель строится на произвольном наборе признаков и затем оценивается

только по ассигасу. В финансовых задачах важно, чтобы целевая переменная, признаки и метрики качества имели экономическую интерпретацию. В противном случае даже высокая формальная точность не гарантирует применимости результата.

Следовательно, инвестиционный риск в данной работе понимается как будущая реализованная уязвимость акции к неблагоприятным рыночным и ликвидностным сценариям, измеряемая через набор риск-компонент и классифицируемая на три уровня. Такая постановка служит основой для дальнейшего анализа данных, формул и ML-архитектуры.

1.2. Ручной и экспертный подход к классификации инвестиционных рисков

В традиционном инвестиционном анализе классификация риска часто выполняется экспертным способом. Аналитик собирает данные о компании, анализирует динамику цены, сравнивает финансовые показатели с аналогами, оценивает макроэкономический фон и присваивает активу условный уровень риска. Такой подход остается распространенным, поскольку он позволяет учитывать контекст, который трудно полностью формализовать.

Ручной анализ обычно включает несколько этапов: сбор рыночных и финансовых данных, расчет базовых показателей, экспертную интерпретацию, сравнение с историческими значениями или отраслевыми ориентирами и итоговое присвоение категории риска. На каждом этапе аналитик принимает решения: какие периоды учитывать, какие аномалии считать значимыми, какие показатели считать приоритетными.

Сильная сторона экспертного подхода состоит в способности учитывать качественные факторы. Например, аналитик может принимать во внимание корпоративные события, санкционные ограничения, особенности раскрытия информации, отраслевую цикличность и изменения регулирования. Эти факторы не всегда непосредственно представлены в табличных данных, но могут влиять на риск актива.

Однако для научной постановки важно отделить экспертный анализ как источник понимания предметной области от ручной процедуры как способа регулярной классификации. Экспертные знания необходимы для выбора признаков, формул и критериев оценки, но сама операция классификации большого числа наблюдений должна быть формализована, иначе ее трудно проверить и повторить.

Если классификация выполняется вручную, результат зависит от квалификации специалиста и используемой им методики. Один аналитик может считать главным признаком риска долговую нагрузку, другой - рыночную волатильность, третий - ликвидность торгов. Даже при одинаковых данных итоговая категория может отличаться, поскольку правила принятия решения не всегда записаны в формальном виде.

Кроме субъективности возникает проблема трудоемкости. Для регулярной оценки десятков акций за несколько лет необходимо обработать сотни месячных срезов и десятки признаков. Ручная процедура становится медленной, а при увеличении числа объектов масштабируется почти линейно по трудозатратам. Это ограничивает возможность оперативного обновления оценок.

Воспроизводимость ручного подхода также ограничена. Чтобы повторить результат, необходимо сохранить исходные данные, версии расчетов, формулы, пороги, экспертные комментарии и последовательность решений. На практике часть таких деталей остается вне формального контура. В результате позднее трудно проверить, почему объект был отнесен именно к выбранному классу риска.

Ручной анализ особенно уязвим при работе с временными данными. Аналитик может неявно использовать информацию, которая не была доступна на дату решения, например опубликованную позже отчетность или будущую динамику цены. Для исследовательской работы это критично, поскольку приводит к утечке будущей информации и завышению качества классификации.

Таким образом, экспертный подход в данной работе рассматривается как базовый способ понимания предметной области, но не как достаточный механизм регулярной классификации. Он помогает определить, какие показатели следует включать в модель, однако итоговый процесс должен быть реализован в виде воспроизводимого алгоритма.

Этап ручного анализа	Содержание этапа	Ограничение
Сбор данных	Поиск рыночных цен, отчетности, макроэкономических показателей	Высокая трудоемкость и риск неполноты данных
Расчет показателей	Волатильность, просадка, ликвидность, финансовые коэффициенты	Риск ошибок формул и несогласованности периодов
Интерпретация	Сравнение с аналогами и экспертная оценка контекста	Субъективность и зависимость от квалификации
Присвоение класса	Отнесение объекта к уровню риска	Слабая воспроизводимость и неясность порогов

Таблица показывает, что проблема ручного анализа является не только технической, но и методологической. Для защиты диплома важно подчеркнуть: автоматизация нужна не потому, что экспертный анализ бесполезен, а потому, что регулярная классификация риска требует формализованного, проверяемого и масштабируемого процесса.

1.3. Ограничения ручного анализа и необходимость автоматизации

Основное ограничение ручного анализа заключается в слабой масштабируемости. Если необходимо оценить несколько активов один раз, экспертная процедура может быть приемлемой. Но при переходе к месячной классификации за несколько лет число наблюдений быстро растет. В рассматриваемом проекте model-ready панель содержит сотни месячных наблюдений и более сотни потенциальных признаков, что делает ручную обработку практически неэффективной.

Второе ограничение связано с субъективностью. Даже если аналитик использует одинаковый набор показателей, итоговое решение зависит от того, как он расставляет приоритеты. Например, высокая ликвидность может

компенсировать повышенную волатильность, а сильная фундаментальная позиция может снижать опасения по поводу краткосрочной просадки. Без формальной модели такие компромиссы остаются неявными.

Третье ограничение - низкая воспроизводимость. В научной работе результат должен быть повторяемым при одинаковых входных данных и параметрах. Ручная классификация редко удовлетворяет этому требованию полностью, поскольку часть решений принимается на основании опыта и контекста, не выраженного в данных. ML-пайплайн, напротив, может фиксировать источники данных, параметры, random seed, версию кода и артефакты запуска.

Четвертое ограничение - сложность учета нелинейных взаимосвязей. Инвестиционный риск редко определяется одним фактором. Повышенная ставка, ослабление валюты, рост рыночной волатильности и снижение ликвидности могут усиливать друг друга. Деревья решений и ансамбли деревьев позволяют учитывать такие взаимодействия без ручного задания всех возможных правил.

Пятое ограничение связано с контролем качества. В ручном анализе трудно измерить качество классификации по всей выборке, потому что не всегда существует формализованная эталонная разметка и журнал предсказаний. В автоматизированном подходе можно сравнивать прогнозируемые классы с целевыми классами, построенными по будущим риск-компонентам, и рассчитывать метрики precision, recall, F1-score и confusion matrix.

При этом автоматизация не означает отказ от экономической логики. Напротив, корректный ML-пайплайн должен включать экспертные знания на этапе выбора признаков, построения целевой переменной и интерпретации результатов. Машинное обучение в такой постановке является способом формализации и масштабирования анализа, а не заменой предметной области случайным набором алгоритмов.

Необходимость автоматизации усиливается временной природой данных. Финансовые ряды требуют особой дисциплины: нельзя перемешивать наблюдения случайным образом, нельзя подбирать пороги классов на всей выборке и нельзя использовать отчетность до даты ее публикации. Автоматизированный пайплайн позволяет встроить эти ограничения в код и тем самым снизить риск методологических ошибок.

Следовательно, проблематика ручного анализа в данной работе формулируется как сочетание субъективности, трудоемкости, низкой воспроизводимости, ограниченной масштабируемости и сложности учета многомерных нелинейных зависимостей. Эти ограничения обосновывают переход к автоматической классификации инвестиционных рисков.

Критерий	Ручной подход	Автоматизированный ML-пайплайн
Масштабируемость	Трудозатраты растут с числом активов и периодов	Пакетная обработка наблюдений после настройки процесса
Воспроизводимость	Зависит от сохранности экспертных правил и версий расчетов	Фиксируются код, данные, параметры и артефакты запуска
Нелинейные связи	Учитываются ограниченно и часто интуитивно	Могут выявляться деревьями и нейросетевыми факторами
Проверка качества	Обычно качественная или выборочная	Формальные метрики классификации и диагностика ошибок

1.4. Формальная постановка задачи исследования

Формальная постановка задачи необходима для того, чтобы связать экономическое содержание инвестиционного риска с алгоритмами машинного обучения. В работе объектом наблюдения является пара «акция - дата решения». Для каждой такой пары формируется набор признаков, доступных на дату решения, и целевой класс риска, рассчитанный по будущему окну.

Пусть i обозначает эмитента, t - дату решения, $X_{\{i,t\}}$ - вектор признаков, доступных на дату t , а $y_{\{i,t\}}$ - класс инвестиционного риска. Тогда задача классификации состоит в построении отображения $f: X_{\{i,t\}} \rightarrow y_{\{i,t\}}$, где y

принимает одно из трех значений: low, medium или high. В отличие от регрессионного прогноза, результатом является категория риска, удобная для последующего принятия решений.

$$f(X(i,t)) \rightarrow y(i,t), \text{ где } y(i,t) \in \{low, medium, high\} \quad (1)$$

Здесь $X(i,t)$ - вектор признаков акции i на дату t , а $y(i,t)$ - целевой класс риска, сформированный по будущим риск-компонентам.

Признаковое пространство включает рыночные показатели, показатели ликвидности, макроэкономические переменные, фундаментальные коэффициенты и признаки, извлеченные из отчетности. Такой набор выбран потому, что инвестиционный риск зависит как от поведения самой бумаги, так и от внешнего режима рынка и финансовой устойчивости эмитента.

Целевая переменная строится не экспертной меткой, а на основе будущей реализации риск-компонент: максимальной просадки, downside-volatility, CVaR 95% и будущей неликвидности. Компоненты переводятся в процентильные ранги относительно train-периода, после чего объединяются во взвешенный риск-скор. Пороги классов также рассчитываются только на train-периоде.

Важным требованием является отсутствие утечки будущей информации. Все операции нормализации, расчет порогов, заполнение пропусков, кластеризация режимов и обучение моделей должны выполняться только на обучающем периоде с последующим применением к validation и test. Это требование отражает реальную ситуацию, в которой инвестор принимает решение до того, как будущий риск реализовался.

Качество решения оценивается через метрики классификации: macro-F1, weighted-F1, balanced accuracy, recall и precision для класса high, а также через матрицу ошибок. Дополнительно учитываются временная устойчивость через walk-forward проверку и диагностические показатели дрейфа признаков. Такой набор метрик позволяет оценить не только среднее качество, но и способность модели обнаруживать высокий риск.

1.5. Критерии оценки оптимизации процесса классификации

Так как тема работы сформулирована через оптимизацию процесса автоматической классификации, результат необходимо оценивать не только как качество одной модели. Оптимизация в данном исследовании понимается как улучшение процедуры получения класса риска: от сбора и подготовки данных до формирования предсказаний и сохранения воспроизводимых артефактов. Поэтому критерии оценки делятся на три группы: масштабируемость, воспроизводимость и качество классификации.

Масштабируемость характеризует способность процесса обрабатывать большее число эмитентов, дат и признаков без пропорционального роста ручного труда. В ручной процедуре аналитик фактически повторяет одни и те же действия для каждого актива и периода: загружает данные, рассчитывает показатели, проверяет формулы, сравнивает значения и принимает решение о категории риска. В автоматизированном процессе эти действия задаются один раз в виде алгоритма, после чего применяются пакетно к панели наблюдений.

В данной работе масштабируемость оценивается не обещанием промышленной производительности, а проверяемыми признаками процесса. К ним относятся количество обработанных строк, число использованных признаков, наличие единого входного model-ready набора, сохранение предсказаний для всех test-наблюдений и возможность повторного запуска через командный интерфейс. Такой подход корректнее, чем абстрактное утверждение о том, что машинное обучение всегда масштабируется лучше человека.

Воспроизводимость означает возможность получить тот же результат при одинаковых данных, коде и параметрах. Для исследовательской работы это особенно важно, потому что комиссия должна видеть не только итоговые числа, но и путь их получения. Воспроизводимый процесс фиксирует конфигурацию, границы train, validation и test, правила формирования целевой переменной, список признаков, метрики и файл с предсказаниями.

Точность процесса в данной задаче не сводится к accuracy. Если классы несбалансированы, обычная accuracy может выглядеть приемлемо даже тогда, когда модель плохо обнаруживает высокий риск. Поэтому основными метриками выбраны macro-F1, balanced accuracy, recall класса high, precision класса high, high false negative rate и ordinal adjacent accuracy. Эти метрики связывают статистическое качество с прикладной природой риска.

Для защиты важно заранее объяснить, почему сравнение проводится с baseline-моделью, а не с гипотетическим идеальным экспертом. Цель диплома состоит в разработке формализованного процесса, поэтому baseline задает минимальный автоматизированный уровень: ансамбль деревьев на базовых признаках. Если гибридная архитектура превосходит baseline на test-периоде, можно говорить о приросте качества внутри автоматизированной процедуры.

При этом ручной анализ остается необходимой точкой постановки проблемы. Он показывает, какие решения эксперт обычно принимает неформально: какой горизонт считать значимым, как интерпретировать просадку, как учитывать ликвидность, что делать с отчетностью и каким образом реагировать на макроэкономический фон. Эти решения в работе переведены в признаки, формулы и правила целевой переменной.

Оценка прироста масштабируемости выполняется через сравнение характера операций. В ручной схеме число операций растет вместе с произведением числа активов, дат и показателей. В автоматизированной схеме рост числа наблюдений в первую очередь увеличивает время выполнения кода, но не требует заново формулировать правила классификации. Это принципиальное отличие процесса, а не просто удобство программирования.

Оценка воспроизводимости выполняется через наличие артефактов запуска. Если после обучения сохраняются metrics.json, predictions.csv, feature_importance.csv, model_leaderboard.csv, data_quality_report.csv и run_manifest.json, то результат можно проверить и сопоставить с текстом работы. В ручной процедуре такие артефакты часто отсутствуют или ведутся разрозненно, что усложняет аудит результата.

Оценка качества выполняется через отложенный test-период и walk-forward проверку. Test-период показывает, как выбранная архитектура работает на данных, не использованных при обучении и выборе модели. Walk-forward дополнительно проверяет устойчивость во времени, что важно для финансовых рядов. Если качество в walk-forward нестабильно, это не отменяет результата, но задает честные границы применимости.

$$N = A \cdot T \cdot F \quad (2)$$

Величина N условно отражает объем ручной обработки: A - число активов, T - число дат решения, F - число показателей. При росте любого множителя ручная процедура быстро усложняется.

$$Effect = Metric(hybrid) - Metric(baseline) \quad (3)$$

Прирост качества оценивается как разница выбранной метрики между гибридной архитектурой и базовой автоматизированной моделью.

Критерий	Как оценивается в работе	Почему важен для защиты
Масштабируемость	Размер панели, число признаков, пакетный запуск пайплайна	Показывает, что процесс переносим на большее число наблюдений
Воспроизводимость	Конфигурация, run_manifest, сохраненные метрики и предсказания	Позволяет проверить результат без ручной реконструкции расчетов
Точность	Macro-F1, balanced accuracy, high recall, high FNR	Связывает модель с качеством классификации риска
Временная корректность	Train/validation/test по датам, walk-forward	Исключает подглядывание в будущие периоды
Интерпретируемость	Feature importance, экономическая монотонность классов	Помогает объяснить решения модели с позиции предметной области

Таким образом, вопрос комиссии о приросте масштабируемости, воспроизводимости и точности закрывается не общими словами, а системой проверяемых критериев. Масштабируемость подтверждается пакетной обработкой панели и модульной архитектурой. Воспроизводимость подтверждается сохраненными артефактами запуска. Качество подтверждается сравнением baseline и гибридной архитектуры на отложенном периоде.

Такой подход делает исследование устойчивее: работа не утверждает, что модель безошибочна, и не подменяет научную задачу коммерческой автоматизацией. Она показывает, что ручная экспертная логика может быть формализована, перенесена в алгоритмический процесс и проверена по метрикам, соответствующим финансовой задаче.

Вывод по первой главе состоит в том, что автоматическая классификация инвестиционного риска требует не только выбора алгоритма, но и построения корректной процедуры. Эта процедура должна учитывать экономическую природу риска, ограничения ручного анализа, временную структуру данных и критерии оценки улучшения процесса.

1.6. Границы исследования и основные допущения

Для устойчивой защиты необходимо явно определить границы исследования. Работа не ставит задачу построить инвестиционную рекомендацию, торговую стратегию или промышленную систему управления портфелем. Объектом является именно процесс классификации инвестиционного риска, то есть процедура преобразования данных о финансовом инструменте в категорию low, medium или high.

Такое ограничение важно, потому что качество классификации риска нельзя напрямую отождествлять с доходностью инвестиционной стратегии. Модель может правильно выделять высокорисковые наблюдения, но это еще не означает, что на ее основе можно автоматически покупать или продавать активы. Для торговой стратегии потребовались бы дополнительные блоки: прогноз доходности, учет транзакционных издержек, лимиты портфеля и правила ребалансировки.

В работе рассматриваются акции, представленные в локальном наборе данных. Это означает, что выводы относятся к выбранной панели и периоду наблюдения, а не ко всем финансовым рынкам. Такая граница не является слабостью, если она прямо обозначена: исследование демонстрирует методику, которую затем можно расширять на большее число эмитентов и более длинную историю.

Следующее допущение связано с периодичностью классификации. Решение принимается на месячных срезах, хотя исходные цены являются дневными. Месячная частота выбрана потому, что она снижает шум краткосрочных движений и лучше согласуется с фундаментальными и макроэкономическими данными. Для внутридневного риск-контроля потребовалась бы другая постановка, другие признаки и другой горизонт target.

Допущение о трех классах риска также должно быть явно зафиксировано. Классы low, medium и high являются аналитической шкалой, а не нормативной категорией. Они позволяют сравнивать объекты между собой и оценивать качество модели, но не заменяют профессиональное решение о допустимости инвестиции. В реальном контуре риск-менеджмента такие классы должны дополняться лимитами и экспертным контролем.

Важная граница исследования касается источников данных. В работе используются рыночные, макроэкономические, фундаментальные и отчетные признаки, доступные в проекте. Не используются новости, корпоративные события в полном объеме, санкционные списки, данные стакана заявок и текстовые сообщения в реальном времени. Поэтому модель оценивает существенную, но не исчерпывающую часть факторов риска.

Еще одно допущение связано с будущим окном. Target строится на последующей реализации риска, но само будущее окно не является прогнозируемым напрямую. Модель учится по прошлым признакам приближать класс, который затем определяется по будущим риск-компонентам. Такой подход корректен для supervised learning, но требует осторожности: если структура рынка изменится, связь между признаками и будущим классом может ослабнуть.

Отдельно следует подчеркнуть, что автоматизация не устраняет экспертную роль. Экспертное знание используется при выборе риск-компонент, горизонта, признаков, метрик и интерпретации результатов. Автоматизированный пайплайн оптимизирует повторяемую часть процесса, но

не отменяет необходимости анализировать ограничения модели и экономический смысл полученных классов.

В работе не предполагается, что все ошибки имеют одинаковую цену. Ошибка low вместо high потенциально опаснее, чем ошибка high вместо medium. Именно поэтому в метриках выделяются high recall и high false negative rate. Это допущение соответствует консервативной логике риск-ориентированной классификации, где пропуск существенного риска считается критичным.

Наконец, исследование исходит из того, что оптимизация процесса может быть доказана несколькими типами результатов. Нельзя требовать от одной модели абсолютной точности на финансовом рынке, но можно показать, что процесс стал формализованным, воспроизводимым, проверяемым и более качественным по выбранным метрикам относительно baseline. Именно эта логика используется в последующих главах.

Граница исследования	Что входит в работу	Что не рассматривается
Тип результата	Классификация риска low/medium/high	Торговая рекомендация или портфельная оптимизация
Частота решения	Месячный срез по акции	Внутридневная или высокочастотная торговля
Данные	Рыночные, макро, фундаментальные, отчетные признаки	Полный новостной поток и стакан заявок
Качество	Метрики классификации и анализ ошибок	Гарантия прибыли или нормативный рейтинг
Роль эксперта	Выбор признаков, target и интерпретация	Полное исключение экспертной оценки

Вывод по первой главе: задача автоматической классификации инвестиционного риска должна рассматриваться как формализация и проверка регулярного аналитического процесса. Четкие границы исследования защищают работу от избыточных ожиданий и позволяют оценивать результат по тем критериям, которые действительно соответствуют поставленной цели.

Вывод по первой главе: была обоснована актуальность автоматической классификации инвестиционных рисков, выявлены ограничения ручного

анализа и сформулирована задача разработки ML-пайплайна. Дальнейшая логика работы требует анализа предметной области, данных, формул и методов, которые будут использованы для практической реализации задачи.

ГЛАВА 2. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ КЛАССИФИКАЦИИ ИНВЕСТИЦИОННЫХ РИСКОВ

2.1. Анализ инвестиционного риска как объекта классификации

Вторая глава посвящена анализу предметной области. Ее задача - показать, какие экономические и математические элементы необходимо изучить для построения автоматической классификации инвестиционного риска. В отличие от главы 1, где акцент сделан на постановке задачи и проблематике, здесь рассматриваются данные, показатели и методы, которые затем используются в реализации.

Инвестиционный риск как объект классификации имеет несколько уровней. Первый уровень - рыночный: он отражает изменение цены акции, волатильность доходности и чувствительность к общему движению рынка. Второй уровень - ликвидностный: он показывает, насколько сложно войти в позицию или выйти из нее без существенного влияния на цену. Третий уровень - фундаментальный: он связан с долговой нагрузкой, денежными потоками и устойчивостью бизнеса.

Для классификации риска важно различать текущие признаки и будущие целевые компоненты. Текущие признаки описывают состояние актива на дату решения: волатильность за прошлые периоды, β , объем торгов, макроэкономические показатели, финансовые коэффициенты. Будущие компоненты описывают то, что произошло после даты решения, и используются только для формирования целевого класса.

Такая логика соответствует практическому смыслу риска. Инвестор не знает будущую просадку в момент принятия решения, но может использовать текущие и раскрытые ранее данные для оценки вероятности неблагоприятного сценария. Поэтому модель должна обучаться на исторических примерах связи между доступными признаками и будущей реализацией риска.

Предметная область требует учитывать, что разные признаки измеряются в разных масштабах. Например, ключевая ставка выражается в процентах, объем торгов - в денежных единицах, β является безразмерной величиной, а

CVaR выражается как средняя потеря в хвосте распределения доходности. Поэтому в программной реализации применяется preprocessing: заполнение пропусков, winsorization, signed-log преобразование и стандартизация.

Особенностью российского рынка акций является выраженная секторная неоднородность. Нефтегазовый сектор, банки, металлургия, ретейл и технологические компании по-разному реагируют на процентные ставки, валютный курс и изменение внешнего спроса. По этой причине секторная принадлежность рассматривается как категориальный признак, а для части признаков рассчитываются секторные z-score.

Еще одна особенность - неоднородность раскрытия отчетности. По одним эмитентам доступны регулярные IFRS-отчеты и годовые отчеты, по другим данные могут быть неполными или публиковаться с задержкой. Поэтому сам факт доступности отчетности, лаг публикации и качество извлечения признаков также являются важными элементами предметной области.

Таким образом, риск акций в работе рассматривается как многомерный объект классификации. Он не равен одной формуле, а формируется совокупностью рыночных, ликвидностных, макроэкономических и фундаментальных характеристик. Дальнейшие подразделы показывают, какие данные и формулы позволяют описать эти характеристики в модели.

Блок риска	Содержание	Примеры признаков
Рыночный риск	Изменчивость цены и чувствительность к индексу	return_1d, rolling_vol_20d, beta_60d, momentum_6m
Ликвидностный риск	Сложность покупки или продажи без ценового воздействия	value, amihud_20d, spread_proxy, turnover_ratio
Макроэкономический риск	Внешний режим рынка и стоимость капитала	cbr_key_rate, usd_rub, ofz_slope_10y_2y
Фундаментальный риск	Устойчивость эмитента и долговая нагрузка	net_debt_to_ebitda, interest_coverage, free_cash_flow
Отчетный слой	Сигналы из раскрытия эмитента	report_lag_days, report_financial_pressure, report_text_risk_density

2.2. Анализ исходных данных для оценки инвестиционных рисков

В исследовании используется набор данных по 18 российским акциям. Дневные рыночные данные содержат 19422 наблюдения за период с 2022-01-03 по 2026-05-12. На их основе формируются месячные срезы, поскольку классификация риска выполняется на уровне регулярной даты решения, а не по каждому торговому дню.

Итоговая месячная *model-ready* панель содержит 932 строк и 135 столбцов за период с 2022-01-31 по 2026-05-12. В панели представлены 18 тикеров из 7 секторных групп. Такой формат удобен для финансовой задачи: он снижает шум дневных колебаний и позволяет объединять рыночные, макроэкономические и фундаментальные данные.

Данные о ценах используются для расчета доходности, волатильности, максимальной просадки, *momentum* и *beta*. Без ценовой истории невозможно построить как текущие рыночные признаки, так и будущие компоненты целевой переменной. Поэтому дневные цены являются базовым источником для всей системы классификации.

Данные об объемах торгов и денежном обороте используются для оценки ликвидности. Для риск-анализа это принципиально: актив может иметь приемлемую доходность, но быть рискованным из-за слабой торгуемости. При снижении ликвидности инвестор сталкивается с более широким спредом, проскальзыванием и невозможностью быстро закрыть позицию.

Макроэкономический набор содержит 1088 строк и включает ключевую ставку, курс USD/RUB, наклон кривой ОФЗ, реализованную волатильность индекса и среднюю корреляцию рынка. Эти признаки описывают режим внешней среды: стоимость капитала, валютное давление, форму кривой доходности и степень синхронности рыночных движений.

Данные рыночного индекса используются для расчета *market_return* и *beta*. *Beta* отражает чувствительность доходности акции к доходности рынка. Если *beta* существенно выше единицы, акция склонна сильнее реагировать на

рыночные движения, что повышает ее рыночный риск при неблагоприятных условиях.

Отдельный слой данных связан с финансовой отчетностью эмитентов. В проекте сформировано 221 строк отчетных признаков по 15 эмитентам. Эти признаки включают финансовые показатели, текстовые risk-signals, лаг публикации, качество извлечения и показатели долговой нагрузки. Такой слой позволяет учитывать не только поведение цены, но и состояние компании.

Принципиальным является point-in-time присоединение отчетности. Отчет за некоторый период не считается доступным до даты публикации. Если использовать report_date вместо publish_date, модель может получить информацию, которая на дату решения еще не была раскрыта. Это привело бы к утечке будущей информации и некорректной оценке качества.

Именно поэтому данные в работе рассматриваются не как произвольная таблица, а как временная система наблюдений. Каждый признак должен быть доступен на дату решения, а каждая целевая компонента должна относиться к будущему окну. Такое разделение является необходимым условием корректной автоматической классификации инвестиционного риска.

Источник данных	Назначение	Использование в модели
Дневные цены MOEX	История цены, объема и оборота	Доходность, волатильность, просадка, ликвидность
Индекс рынка	Бенчмарк общего движения рынка	market_return, beta_60d
Макроэкономические данные	Описание внешнего режима	ставка, USD/RUB, ОФЗ, волатильность индекса
Финансовая отчетность	Оценка устойчивости эмитента	долг, EBITDA, cash-flow, текстовые сигналы риска
Universe эмитентов	Состав акций и секторная принадлежность	категориальный признак sector, секторные z-score

2.3. Анализ экономических и математических показателей инвестиционного риска

Для защиты работы важно, чтобы каждая формула была не просто выписана, а обоснована с точки зрения предметной области. Ниже приведены

основные показатели, которые используются для формирования признаков, целевой переменной и оценки результатов.

$$r(i,t) = [P(i,t) - P(i,t-1)] / P(i,t-1) \quad (4)$$

Доходность $r(i,t)$ показывает относительное изменение цены акции i между датами $t-1$ и t . $P(i,t)$ - цена закрытия на дату t . Доходность является базовой величиной для расчета волатильности, beta, CVaR и других риск-метрик.

$$\bar{r}(i) = (1 / T) \cdot \sum_{(t=1..T)} r(i,t) \quad (5)$$

Средняя доходность отражает средний результат актива за рассматриваемый период T . В задаче классификации она используется не как самостоятельная цель, а как вспомогательная статистика для анализа поведения доходности.

$$\sigma(i) = \sqrt{[1 / (T - 1)] \cdot \sum_{(t=1..T)} [r(i,t) - \bar{r}(i)]^2} \quad (6)$$

Волатильность $\sigma(i)$ измеряет изменчивость доходности. В кодовой базе ей соответствует `rolling_vol_20d`, рассчитанная по скользящему окну. Этот показатель отражает рыночный риск, но не различает положительные и отрицательные отклонения.

$$\sigma_{down}(i) = \sqrt{[1 / (ndown - 1)] \cdot \sum_{[r(i,t) < 0]} [r(i,t) - \bar{r}_{down}(i)]^2} \quad (7)$$

Downside-volatility учитывает только отрицательные доходности. Такой показатель ближе к восприятию риска инвестором, поскольку положительные отклонения обычно не являются нежелательным событием.

$$MDD(i) = \max(t) \{ [\max(s \leq t) P(i,s) - P(i,t)] / \max(s \leq t) P(i,s) \} \quad (8)$$

Максимальная просадка MDD показывает наибольшее относительное падение цены от предыдущего максимума. В целевой переменной используется `future_max_drawdown`, рассчитанная по будущему окну.

$$VaR(\alpha) = -q_{\alpha}(r(i)) \quad (9)$$

Value-at-Risk показывает квантиль потерь при заданном уровне α . В данной работе он рассматривается как теоретическая основа для хвостовых метрик риска.

$$CVaR(\alpha) = -E[r(i) \mid r(i) \leq q\alpha(r(i))] \quad (10)$$

Conditional Value-at-Risk показывает среднюю потерю в хвосте распределения. В реализации используется future_cvar_95 как положительная величина хвостовой потери по будущим доходностям.

$$ILLIQ(i) = (1 / T) \cdot \sum_{t=1..T} |r(i,t)| / VALUE(i,t) \quad (11)$$

Показатель неликвидности по смыслу близок к метрике Amihud: он связывает абсолютную доходность с денежным оборотом. Чем выше значение, тем сильнее движение цены на единицу оборота и тем выше ликвидностный риск.

$$\beta(i) = Cov[r(i), r(m)] / Var[r(m)] \quad (12)$$

Beta отражает чувствительность акции к рынку. r_m - доходность рыночного индекса. В реализации рассчитывается beta_60d по скользящему окну.

$$RiskScore(i,t) = 0,35 \cdot p(MDD) + 0,30 \cdot p(\sigma_{down}) + 0,20 \cdot p(CVaR) + 0,15 \cdot p(ILLIQ) \quad (13)$$

Итоговый риск-скор объединяет процентильные ранги будущих компонент риска. p(.) означает процентиль относительно train-периода. Вес максимальной просадки выбран наибольшим, поскольку глубина потерь является наиболее понятной прикладной характеристикой риска.

Показатель	Экономический смысл	Роль в работе
Доходность	Изменение цены актива	База для признаков и риск-компонент
Волатильность	Разброс доходности	Текущий рыночный риск
Downside-volatility	Разброс отрицательных доходностей	Будущая компонента риска и признак
Максимальная просадка	Глубина падения от максимума	Ключевая будущая компонента риска
CVaR 95%	Средняя хвостовая потеря	Оценка экстремального риска
Amihud/ILLIQ	Ценовое движение на единицу оборота	Ликвидностный риск
Beta	Чувствительность к рынку	Рыночная чувствительность актива

Формулы целевой переменной задают не экспертную оценку, а наблюдаемую будущую реализацию риска. Это принципиально отличает работу от субъективной разметки: модель учится приближать классы, которые выводятся из будущих риск-компонент, а не из произвольного мнения аналитика.

Для классификации используется train-only логика порогов. Сначала по обучающему периоду рассчитываются процентильные распределения компонент, затем на их основе формируются риск-скоры и пороги low/medium/high. После этого те же пороги применяются к validation и test. Такой подход предотвращает подглядывание в будущее.

Помимо риск-метрик используются производные признаки, отражающие взаимодействия факторов. Например, liquidity_stress объединяет Amihud, спред и денежный оборот, beta_vol_interaction связывает рыночную чувствительность с волатильностью, а macro_pressure агрегирует ставку, волатильность индекса, корреляцию рынка и наклон кривой ОФЗ. Эти признаки имеют экономическую интерпретацию и помогают моделям учитывать нелинейные зависимости.

Таким образом, формулы во второй главе являются мостом между предметной областью и программной реализацией. В третьей главе эти формулы используются для расчета признаков, построения целевой переменной и интерпретации качества моделей.

2.4. Анализ применимости методов машинного обучения к задаче классификации риска

После определения данных и формул необходимо выбрать методы машинного обучения. Для рассматриваемой задачи важны три свойства: способность работать с табличными данными, интерпретируемость и возможность учитывать нелинейные зависимости. Именно поэтому в работе используется комбинация деревьев решений, кластеризационного анализа и искусственных нейронных сетей.

Деревья решений подходят для финансовых табличных данных, поскольку они строят правила вида «если признак выше порога, перейти в

другую ветвь». Такие правила проще интерпретировать, чем коэффициенты сложной нелинейной модели. В работе используются не одиночные деревья, а ансамбли: Random Forest, Extra Trees и Gradient Boosting. Ансамбли повышают устойчивость и уменьшают риск переобучения одного дерева.

$$Gini(S) = 1 - \sum_{c=1..K} p(c)^2 \quad (14)$$

Критерий Gini используется для оценки неоднородности узла дерева. p_c - доля объектов класса c в узле S , K - число классов.

$$Gain = Impurity(parent) - \sum_j [|S(j)| / |S|] \cdot Impurity(S(j)) \quad (15)$$

Прирост качества разбиения показывает, насколько выбранное условие уменьшает неоднородность классов.

Кластеризационный анализ используется не для прямой замены классификатора, а как слой выделения рыночных режимов. Макроэкономические признаки могут образовывать состояния рынка: более спокойное, стрессовое, высокоставочное или волатильное. Если добавить метку режима как признак, классификатор получает информацию о внешнем контексте, в котором наблюдается акция.

$$\min_{C(1)..C(k)}: \sum_{j=1..k} \sum_{x \in C(j)} \|x - \mu(j)\|^2 \quad (16)$$

Задача KMeans состоит в минимизации суммы квадратов расстояний от объектов до центров кластеров. В работе кластеризация применяется к макроэкономическим признакам, а центры обучаются только на train-периоде.

Искусственные нейронные сети применяются для извлечения латентных факторов из числовых признаков. В рассматриваемой реализации используется автоэнкодер: encoder переводит исходные признаки в компактное скрытое пространство, а decoder восстанавливает исходный вектор. В основном запуске применяется PyTorch backend с PCA-инициализацией линейного bottleneck autoencoder, что сохраняет устойчивость факторного представления на небольшой финансовой панели.

$$L(\theta) = (1 / n) \cdot \sum_{i=1..n} \|x(i) - g_{\theta}(f_{\theta}(x(i)))\|^2 \quad (17)$$

Функция потерь автоэнкодера минимизирует ошибку восстановления. f_{θ} - encoder, g_{θ} - decoder, x_i - вектор признаков наблюдения.

Объединение методов позволяет распределить роли между компонентами пайплайна. Деревья обеспечивают основную классификацию, кластеризация добавляет рыночный режим, а нейросетевой слой формирует компактные латентные признаки. Такая архитектура соответствует теме работы и одновременно сохраняет прикладную интерпретируемость.

Для оценки качества используются macro-F1, weighted-F1, balanced accuracy, high recall, high precision, high false negative rate и ordinal adjacent accuracy. Macro-F1 важен при дисбалансе классов, high recall отражает способность находить высокий риск, а adjacent accuracy учитывает порядковую природу классов low-medium-high.

$$Precision(c) = TP(c) / [TP(c) + FP(c)] \quad (18)$$

Precision показывает, какая доля объектов, отнесенных к классу c , действительно принадлежит этому классу.

$$Recall(c) = TP(c) / [TP(c) + FN(c)] \quad (19)$$

Recall показывает, какая доля объектов класса c была найдена моделью.

$$F1(c) = 2 \cdot Precision(c) \cdot Recall(c) / [Precision(c) + Recall(c)] \quad (20)$$

F1-score является гармоническим средним precision и recall.

$$Macro-F1 = (1 / K) \cdot \sum_{c=1..K} F1(c) \quad (21)$$

Macro-F1 усредняет качество по классам и не позволяет крупному классу полностью доминировать в итоговой оценке.

2.5. Обоснование целевой переменной и признакового пространства

Целевая переменная является центральным элементом всей работы, потому что именно она определяет, чему обучается модель. В задаче инвестиционного риска нельзя ограничиться произвольной экспертной меткой, если цель состоит в построении воспроизводимого процесса. Поэтому целевой класс формируется на основе будущей реализации риска, а не на основе субъективного описания эмитента.

Будущее окно выбрано так, чтобы класс отражал не мгновенное движение цены, а последующий риск владения активом. В реализации используется горизонт 126 торговых дней, что примерно соответствует полугодовому периоду. Такой горизонт достаточно длинный, чтобы включить рыночные колебания и потенциальные стрессовые движения, но не настолько длинный, чтобы класс полностью терял связь с текущими признаками.

Целевая переменная включает четыре компоненты. Максимальная просадка описывает глубину падения капитала от локального максимума. Downside-volatility показывает регулярность отрицательных колебаний. CVaR 95% отражает среднюю потерю в неблагоприятном хвосте распределения. Будущая неликвидность учитывает, насколько движение цены связано с ограниченным денежным оборотом.

Выбор весов в `risk_score` должен быть объяснен экономически. Наибольший вес присвоен максимальной просадке, поскольку она наиболее прямо связана с потерей капитала. Downside-volatility получает второй вес, так как отражает повторяемость негативных движений. CVaR добавляет хвостовой риск, а неликвидность фиксирует сложность выхода из позиции. Такая структура делает риск-скор не одномерным, а многокомпонентным.

Процентильное ранжирование компонент решает проблему разных единиц измерения. Просадка выражается в относительных долях, волатильность рассчитывается по доходностям, CVaR является хвостовой потерей, а неликвидность зависит от оборота. Без приведения к процентилям простое сложение таких величин было бы методологически слабым. Ранг относительно `train`-периода делает компоненты сопоставимыми.

Границы классов `low`, `medium` и `high` формируются по распределению `risk_score` в обучающей выборке. Это означает, что `validation` и `test` не участвуют в подборе порогов. В финансовых данных такая дисциплина критична: если пороги вычислены на всей истории, будущие периоды косвенно влияют на прошлую разметку, и качество модели оказывается завышенным.

Три класса риска выбраны как компромисс между детализацией и устойчивостью. Двухклассовая постановка слишком грубо разделяет объекты на рискованные и нерискованные. Более дробная шкала требовала бы большего числа наблюдений и усилила бы нестабильность границ. Шкала low-medium-high остается понятной для интерпретации и достаточной для оценки качества.

Признаковое пространство строится так, чтобы каждая группа признаков отражала отдельный аспект риска. Рыночные признаки описывают поведение цены и чувствительность к рынку. Ликвидностные признаки показывают возможность входа и выхода из позиции. Макроэкономические признаки задают внешний режим. Фундаментальные и отчетные признаки описывают устойчивость эмитента и качество раскрытия информации.

Важно, что признаки не должны повторять будущие компоненты целевой переменной. Например, будущая просадка используется только для формирования target , но не может попасть в $X(i,t)$. В признаки включаются только сведения, доступные на дату решения: исторические доходности, текущие макроэкономические значения, опубликованная отчетность и расчетные показатели на прошлом окне.

В работе используются не только исходные признаки, но и производные экономические взаимодействия. Например, $\text{beta_vol_interaction}$ показывает сочетание рыночной чувствительности и волатильности, $\text{liquidity_vol_interaction}$ соединяет ликвидность и изменчивость, а rate_fx_pressure агрегирует процентно-валютное давление. Такие признаки помогают деревьям решений строить правила, близкие к экспертной логике.

Cross-sectional признаки важны потому, что инвестиционный риск относителен. Одна и та же абсолютная волатильность может быть высокой в спокойном рынке и обычной в стрессовом. Ранжирование в месячном сечении показывает, насколько конкретная бумага выделяется среди остальных активов в тот же момент времени.

Секторные нормировки нужны для корректного сравнения компаний. Финансовые коэффициенты в банках, нефтегазе, металлургии и розничной

торговле имеют разные нормальные диапазоны. Если сравнивать все эмитенты как однородную группу, модель может принять отраслевую специфику за риск. Секторные z-score частично решают эту проблему.

$$p_k(i,t) = \text{rank_train}(z_k(i,t)) / N_{\text{train}} \quad (22)$$

Здесь $p_k(i,t)$ - процентильная оценка k -й риск-компоненты относительно обучающего периода; $z_k(i,t)$ - значение соответствующей будущей компоненты.

$$y(i,t) = \text{low, если } \text{Score} \leq q1; \text{ medium, если } q1 < \text{Score} \leq q2; \text{ high, если } \text{Score} > q2 \quad (23)$$

Класс риска определяется порогами $q1$ и $q2$, рассчитанными только на train-периоде.

Группа признаков	Примеры	Экономическая роль
Рыночные	return_1d, rolling_vol_20d, momentum_6m, beta_60d	Характеризуют динамику цены и чувствительность к рынку
Ликвидностные	turnover_ratio, amihud_20d, spread_proxy	Описывают риск совершения сделки и выхода из позиции
Макроэкономические	cbr_key_rate, usd_rub, ofz_slope, market correlation	Задают режим внешней среды
Фундаментальные	net_debt_to_ebitda, interest_coverage, free_cash_flow	Показывают устойчивость компании
Отчетные	report_lag_days, report_text_risk_density, extraction_quality	Учитывают качество раскрытия и текстовые сигналы риска
Производные	macro_pressure, liquidity_stress, fundamental_fragility	Формализуют взаимодействия факторов

В рассматриваемой панели используются 932 месячных наблюдения и 135 столбцов. Это не означает, что все столбцы автоматически являются признаками модели: часть полей служит идентификаторами, часть относится к будущим target-компонентам, часть используется для контроля качества. Такое разделение обязательно должно быть отражено в исследовании, чтобы показать отсутствие утечки данных.

Дневная база содержит 19422 строк по 18 тикерам. Из нее формируются месячные срезы, потому что инвестиционная классификация в работе понимается как регулярное решение на отчетную дату, а не как внутридневной сигнал. Месячный шаг также лучше согласуется с фундаментальной отчетностью и макроэкономическими рядами.

Отчетный слой содержит 221 строк по 15 эмитентам. Его роль состоит не только в добавлении финансовых коэффициентов, но и в фиксации доступности данных. Если отчетность отсутствует, опубликована с большим лагом или извлечена с низким качеством, это не следует игнорировать: неопределенность раскрытия может сама быть фактором риска.

Итоговая логика целевой переменной делает работу защищаемой: классы риска не берутся из воздуха и не подгоняются под результат модели. Они выводятся из формализованных будущих компонент, выбранных на основании экономического смысла инвестиционного риска. Это позволяет связать математическую часть, данные и программную реализацию в один последовательный контур.

2.6. Протокол проверки качества и предотвращение утечки данных

Временная структура финансовых данных требует более строгого протокола проверки, чем обычная табличная классификация. Нельзя случайно перемешивать наблюдения между train и test, потому что тогда модель получает информацию из будущих периодов. Поэтому разделение выборки выполняется по датам: сначала train, затем validation, затем test.

Validation-период используется для выбора архитектуры, калибровки вероятностей и настройки policy-порогов. Test-период используется только для финальной оценки. Такая схема отделяет этап выбора модели от этапа проверки качества. Если оценивать все решения на test, то test постепенно превращается в скрытую validation-выборку и перестает быть независимой проверкой.

Point-in-time логика особенно важна для финансовой отчетности. Отчет за период может относиться к прошлому кварталу, но быть опубликован позже даты решения. Если присоединить его по отчетному периоду, модель получит

информацию, которой инвестор на дату решения не обладал. Поэтому в работе отчетные признаки должны присоединяться по `publish_date`.

Предобработка признаков также должна обучаться только на `train`. Медианы для заполнения пропусков, границы winsorization, параметры стандартизации и преобразования распределений нельзя рассчитывать на всей выборке. Иначе статистики `validation` и `test` попадут в процесс обучения, даже если сами целевые значения не используются.

Для контроля качества данных применяются проверки ключей, дат, пропусков и доступности целевых компонент. Дубликаты по паре `decision_date` и `ticker` недопустимы, поскольку один объект наблюдения не должен иметь две разные строки признаков. Наблюдения без будущего окна не могут использоваться для обучения, потому что их целевой класс неопределен.

Для контроля качества модели применяется несколько групп метрик. Macro-F1 показывает усредненное качество по классам и защищает от доминирования наиболее частого класса. Balanced accuracy усредняет recall по классам. High recall и high false negative rate отражают способность модели не пропускать высокий риск. Ordinal adjacent accuracy учитывает, что ошибка `high`→`medium` менее груба, чем `high`→`low`.

Матрица ошибок нужна для интерпретации результатов. По одной метрике нельзя понять, какие именно классы модель путает. В финансовой задаче особенно важно видеть, сколько фактических `high`-наблюдений ушло в `low` или `medium`. Эта информация напрямую связана с риск-ориентированной ценностью классификатора.

Walk-forward проверка дополняет фиксированное `train/validation/test` разбиение. Она имитирует последовательное применение модели во времени: обучение проводится на прошлом окне, проверка - на следующем периоде. Такой подход показывает, насколько модель устойчива при смене рыночных условий и насколько результат зависит от выбранной даты разбиения.

Диагностика дрейфа признаков позволяет оценить, насколько распределения `validation` и `test` отличаются от `train`. В финансовых данных

дрейф почти неизбежен, потому что меняются ставка, курс, волатильность, ликвидность и состав раскрытия. Важно не игнорировать дрейф, а явно включить его в анализ ограничений модели.

Экономическая монотонность классов является дополнительной проверкой смысла. Если средняя *future_max_drawdown* или *future_cvar_95* не растёт от low к high, то классификация может быть формально точной, но экономически сомнительной. Поэтому в работе следует проверять не только F1-score, но и порядок классов по ключевым риск-компонентам.

$$FNR_high = FN_high / (TP_high + FN_high) \quad (24)$$

High false negative rate показывает долю фактически высокорисковых наблюдений, которые модель не распознала как high.

$$PSI = \sum(b) [p_test(b) - p_train(b)] \cdot \ln[p_test(b) / p_train(b)] \quad (25)$$

Population Stability Index используется как один из способов оценить сдвиг распределений признаков между периодами.

Риск методологии	Как предотвращается	Где отражается в работе
Утечка будущей информации	Временное разбиение и point-in-time присоединение отчетности	Глава 2 и реализация пайплайна
Подгонка порогов под test	Пороги target и policy обучаются до test-оценки	Описание TargetRanker и выбора архитектуры
Смещение из-за дисбаланса классов	Macro-F1, balanced accuracy, classwise metrics	Раздел оценки качества
Переоценка устойчивости	Walk-forward и диагностика дрейфа	Интерпретация ограничений
Необъяснимость результата	Feature importance и экономическая монотонность	Интерпретация модели

2.7. Связь экономических показателей с признаками модели

Чтобы глава 2 не выглядела набором отдельных формул, необходимо показать, как каждая экономическая величина переходит в конкретный признак модели. Такой переход является центральным для защиты: комиссия должна видеть, что признаки рассчитаны не потому, что они случайно есть в таблице, а потому что каждый из них отражает определенную сторону инвестиционного риска.

Доходность является исходным элементом почти всех рыночных признаков. Из нее рассчитываются momentum, волатильность, downside-volatility, beta и компоненты хвостового риска. Поэтому качество расчета доходности влияет на весь последующий pipeline. В реализации важно использовать согласованную цену закрытия и корректную сортировку по тикеру и дате.

Волатильность отражает разброс доходности, но сама по себе не говорит, были ли отклонения положительными или отрицательными. Поэтому она используется как общий признак рыночной изменчивости, а downside-volatility - как более риск-ориентированная величина. Такое разделение позволяет модели отличать актив с сильными колебаниями вверх от актива с регулярными отрицательными движениями.

Momentum показывает накопленное направление движения цены за выбранный период. В инвестиционном риске momentum может иметь двойственную роль. С одной стороны, сильный положительный momentum может указывать на устойчивость спроса. С другой стороны, перегретый рост может усиливать риск последующей коррекции. Поэтому momentum включается не как линейное правило, а как признак для дерева решений, которое может учитывать контекст.

Beta связывает динамику акции с динамикой рыночного индекса. Высокая beta означает, что актив чувствителен к общерыночным движениям. Однако beta не заменяет другие показатели: акция может иметь низкую рыночную чувствительность, но высокий специфический риск из-за низкой ликвидности, слабой отчетности или долговой нагрузки. Поэтому beta используется совместно с фундаментальными и ликвидностными признаками.

Amihud illiquidity связывает абсолютную доходность с денежным оборотом. Если небольшая сумма торгов сопровождается значительным движением цены, актив труднее считать устойчивым. В реализации этот показатель дополняется turnover_ratio и avg_daily_traded_value_20d, потому что

ликвидность имеет несколько сторон: объем рынка, интенсивность оборота и ценовое воздействие сделки.

Макроэкономические признаки задают фон, в котором интерпретируются показатели конкретной бумаги. Высокая ключевая ставка повышает стоимость капитала и давление на долговые компании. Ослабление валюты может по-разному влиять на экспортеров и импортозависимые бизнесы. Рост рыночной корреляции часто указывает на стрессовый режим, когда индивидуальные различия между бумагами временно снижаются.

Показатели отчетности переводят финансовое состояние компании в числовой вид. Net debt to EBITDA отражает долговую нагрузку, interest coverage - способность обслуживать долг, free cash flow - внутренний ресурс финансирования, margins - операционную устойчивость. Если эти признаки соединяются с рыночными данными, модель получает более полный профиль риска, чем при анализе одной цены.

Признаки качества отчетности имеют самостоятельный смысл. Большой лаг публикации, низкое качество извлечения или высокая плотность текстовых риск-сигналов повышают неопределенность. Для инвестора неопределенность раскрытия является частью риска, потому что неполная информация ухудшает способность оценить будущие денежные потоки и долговую устойчивость.

Производные признаки нужны для формализации взаимодействий, которые эксперт обычно учитывает интуитивно. Например, высокий долг опаснее при высокой ставке; низкая ликвидность опаснее при высокой волатильности; высокая beta опаснее в стрессовом макрорежиме. Если оставить только исходные признаки, модель может выявить эти взаимодействия сама, но явные производные признаки помогают ей при ограниченном объеме данных.

Секторные признаки предотвращают грубое сравнение сопоставимых компаний. Высокий долг в капиталоемкой отрасли и высокий долг у компании с нестабильным денежным потоком имеют разный смысл. Секторные z-score позволяют оценивать отклонение эмитента от своей группы, а не только от

всего рынка. Это повышает экономическую корректность признакового пространства.

Признаки пропусков не следует автоматически удалять. В финансовых данных отсутствие значения может быть информативным: компания могла не раскрыть показатель, отчетность могла быть недоступна, или показатель мог быть неприменим к отрасли. Поэтому missing-indicators помогают модели отличать нулевое значение от отсутствия информации.

Связь формул с признаками также важна для третьей главы. Когда в реализации упоминаются `rolling_vol_20d`, `beta_60d` или `future_cvar_95`, читатель должен понимать, что это не технические названия столбцов, а программные воплощения экономических показателей. Это делает текст последовательным: глава 2 объясняет смысл, глава 3 показывает реализацию.

Такой подход защищает работу от критики о случайном наборе признаков. В дипломе используется не произвольная таблица, а структурированное признаковое пространство, где рыночные, ликвидностные, макроэкономические, фундаментальные и отчетные данные выполняют разные аналитические функции.

Экономический показатель	Программный признак	Интерпретация в классификации
Доходность	<code>return_1d</code> , <code>market_return</code>	Основа для динамики цены и расчетов риска
Волатильность	<code>rolling_vol_20d</code>	Общая изменчивость доходности
Негативная волатильность	<code>downside_vol_60d</code>	Частота и сила отрицательных движений
Momentum	<code>momentum_6m</code>	Накопленное направление движения цены
Beta	<code>beta_60d</code>	Чувствительность к рыночному индексу
Ликвидность	<code>amihud_20d</code> , <code>turnover_ratio</code>	Ценовое воздействие и активность торгов
Макрофон	<code>cbr_key_rate</code> , <code>usd_rub</code> , <code>ofz_slope</code>	Стоимость капитала и внешний режим
Финансовая устойчивость	<code>net_debt_to_ebitda</code> , <code>interest_coverage</code>	Долговая нагрузка и способность обслуживать долг
Качество раскрытия	<code>report_lag_days</code> , <code>extraction_quality</code>	Информационная неопределенность

Вывод по разделу 2.7: экономические показатели и программные признаки находятся в прямой логической связи. Это позволяет в третьей главе обосновывать реализацию не технически, а предметно: каждый значимый блок кода соответствует определенному аспекту инвестиционного риска.

2.8. Обоснование гибридной архитектуры классификации

Выбор гибридной архитектуры связан с тем, что задача классификации инвестиционного риска неоднородна. В ней одновременно присутствуют табличные финансовые признаки, временная структура, макроэкономические режимы, нелинейные взаимодействия и ограниченный объем размеченных наблюдений. Один метод редко закрывает все эти требования одинаково хорошо.

Линейные модели полезны как базовый ориентир, но они требуют заранее заданной формы зависимости между признаками и классом. В финансовом риске такая зависимость часто нелинейна: влияние ликвидности может усиливаться при высокой волатильности, а значение долговой нагрузки меняется в зависимости от ставки. Поэтому линейная модель может быть слишком жесткой для основной архитектуры.

Методы ближайших соседей также не являются оптимальным выбором для основной реализации. Они чувствительны к масштабу признаков, размерности пространства и шуму в данных. Финансовая панель содержит признаки разных типов и распределений, поэтому расстояние между наблюдениями не всегда имеет понятный экономический смысл без сложной настройки метрики.

Деревья решений и их ансамбли подходят лучше, потому что они умеют строить пороговые правила. В риск-анализе такие правила естественны: высокая ставка, низкая ликвидность, повышенная волатильность или слабое покрытие процентов могут переводить актив в другую область риска. Ансамбли деревьев уменьшают нестабильность одиночного дерева и позволяют учитывать много признаков без ручного задания всех взаимодействий.

Однако одних деревьев недостаточно, если рыночный режим меняется. Один и тот же уровень β или волатильности имеет разный смысл в спокойный и стрессовый период. Поэтому в архитектуру добавляется кластеризационный слой, который выделяет режимы по макроэкономическим признакам. Этот слой не заменяет классификатор, а расширяет контекст принятия решения.

Кластеризация в данной работе выполняет роль структурирования внешней среды. Она помогает модели различать периоды, в которых поведение акций подчиняется разной логике. Например, при высокой рыночной корреляции индивидуальная фундаментальная устойчивость может временно играть меньшую роль, а при спокойном рынке различия между компаниями становятся более заметными.

Нейросетевой или факторный слой решает другую задачу: он сжимает многомерное числовое пространство в компактные латентные признаки. Это особенно полезно, когда признаки коррелируют между собой или частично дублируют одну экономическую сущность. Латентные факторы могут передать в классификатор обобщенную информацию без увеличения числа ручных правил.

Комбинация методов делает архитектуру более устойчивой с методической точки зрения. Деревья обеспечивают интерпретируемую основу, кластеризация добавляет режим рынка, а латентные факторы помогают работать с высокой размерностью. Именно такое распределение ролей соответствует теме работы и делает объединение методов не формальным, а содержательным.

При этом гибридная архитектура не должна усложняться автоматически. Каждый дополнительный слой должен проверяться по `validation` и `test`. Если секторный `overlay` или отчетный слой не дает устойчивого прироста, его нельзя объявлять успешным только потому, что он выглядит сложнее. В работе это учитывается через `model leaderboard` и выбор итоговой архитектуры по заданному критерию.

Гибридный подход также помогает отвечать на вопрос о точности. Если baseline на деревьях показывает один уровень качества, а добавление режима и латентных факторов улучшает test-метрики, можно говорить о полезности объединения методов. Если улучшения нет, тема потребовала бы другой реализации или пересмотра признаков. Поэтому сравнение архитектур является обязательной частью исследования.

Отдельное значение имеет интерпретируемость. Полностью нейросетевая модель могла бы быть труднее защищаемой, особенно при небольшом объеме финансовых данных. Использование нейросетевого слоя как источника латентных факторов, а деревьев как итогового классификатора сохраняет баланс между нелинейным представлением и объяснимостью результата.

Таким образом, выбранная архитектура отражает структуру самой предметной области. Инвестиционный риск формируется не одним фактором, а сочетанием состояния рынка, свойств эмитента, ликвидности и будущей реализации потерь. Поэтому модель также строится как сочетание компонентов, каждый из которых отвечает за отдельный уровень анализа.

Метод	Сильная сторона	Ограничение	Роль в работе
Ансамбли деревьев	Нелинейные пороговые правила и importance	Могут переобучаться на малой выборке	Основной классификатор
Кластеризация	Выделение режимов без ручной разметки	Не дает целевой класс напрямую	Контекст рыночной среды
Автоэнкодер/ РСА	Сжатие многомерных числовых признаков	Требует контроля устойчивости	Латентные факторы
Секторный overlay	Учет отраслевой неоднородности	Нужен достаточный объем по сектору	Проверяемое усложнение
Baseline	Простая точка сравнения	Не учитывает все дополнительные слои	Контроль полезности гибрида

Вывод по разделу 2.8: гибридная архитектура выбрана не ради усложнения, а потому что отдельные компоненты решают разные методические

задачи. Такая логика позволяет в третьей главе оценивать вклад каждого слоя и объяснять итоговый результат через сравнение с baseline.

Такой протокол делает вторую главу не обзором отдельных формул, а методической основой всей реализации. Сначала определяется, что именно считается риском, затем выбираются данные и признаки, после этого задаются правила проверки качества. В третьей главе остается показать, как эти правила реализованы в коде и какие результаты они дали.

Вывод по второй главе состоит в том, что предметная область инвестиционного риска требует одновременного учета экономического смысла, временной доступности данных и статистической проверки качества. Без этого ML-модель легко превращается в формальный классификатор, который может показывать числа, но не выдерживать методологическую критику.

Вывод по второй главе: проведен анализ предметной области классификации инвестиционных рисков, обоснован выбор исходных данных, рассмотрены экономические и математические показатели риска, а также определены методы машинного обучения, применимые для построения автоматизированной системы классификации.

ГЛАВА 3. РЕАЛИЗАЦИЯ ML-ПАЙПЛАЙНА И ОЦЕНКА РЕЗУЛЬТАТОВ

3.1. Архитектура разработанного ML-пайплайна

Практическая реализация начинается с переноса постановки из первых двух глав в последовательный программный процесс. Если во второй главе были определены данные, формулы и правила проверки, то в третьей главе эти элементы превращаются в модули Python-пакета `risk_pipeline`. Такой переход важен: он показывает, что реализация следует заранее заданной методике, а не представляет собой набор разрозненных скриптов.

Пайплайн устроен как цепочка зависимых этапов. Сначала формируется панель наблюдений по парам акция-дата решения. Затем рассчитываются признаки, доступные на дату решения, присоединяются макроэкономические и отчетные данные, строятся будущие компоненты риска, формируется целевой класс и выполняется временное разбиение. Только после этого обучаются модели и проводится оценка качества.

Разделение данных на `train`, `validation` и `test` выполняется по времени, а не случайным образом. В свежем прогоне использовались следующие объемы: `train` - 248 наблюдений, `validation` - 102 наблюдения, `test` - 102 наблюдения. Такая схема соответствует реальному применению: модель обучается на прошлом, настраивается на следующем периоде и проверяется на более позднем отрезке.

После запуска сохраняются артефакты, необходимые для проверки результата: `metrics.json`, `predictions.csv`, `feature_importance.csv`, `model_leaderboard.csv`, `walk_forward_report.csv`, `feature_drift_report.csv`, `data_quality_report.csv`, `run_manifest.json` и `model_package.joblib`. Их наличие превращает результат из разового запуска в воспроизводимый исследовательский процесс, где итоговые числа можно сопоставить с конкретными данными и параметрами.

Архитектура включает несколько модельных ветвей, каждая из которых проверяет отдельную гипотезу. `Baseline` использует базовые рыночные,

ликвидностные и макроэкономические признаки. Regime branch проверяет вклад кластеризации рыночного режима. Enriched branch добавляет фундаментальные и отчетные данные. ANN plus regime branch проверяет, улучшают ли латентные факторы качество итоговой классификации.

Выбор итоговой архитектуры выполняется на validation-периоде. Основной критерий основан на macro-F1, но дополнительно учитывает recall класса high. Это соответствует риск-ориентированной постановке: модель должна сохранять сбалансированное качество по классам и одновременно не пропускать высокорисковые наблюдения.

Этап	Модуль	Результат
Загрузка данных	data_sources.py, real_data_pipeline.py	daily, macro, market, report features
Feature engineering	features.py, feature_engineering.py	rolling, liquidity, macro, derived features
Target layer	targets.py	future components, risk_score, risk_class
Разбиение	splits.py	temporal train/validation/test, walk- forward
Модели	models.py, ensemble.py	tree ensembles, regime clusters, latent factors
Оценка	evaluation.py, diagnostics.py	метрики, confusion matrix, drift report
Отчетность	reporting.py	RUN_REPORT.md, metrics.json, model package

3.2. Реализация расчета признаков и целевой переменной

Формулы, рассмотренные во второй главе, непосредственно используются в реализации. Доходность рассчитывается как процентное изменение цены закрытия, rolling_vol_20d - как стандартное отклонение доходности по скользящему окну, downside_vol_60d - как волатильность отрицательных доходностей, beta_60d - как отношение ковариации доходности акции и рынка к дисперсии доходности рынка.

Ликвидностные признаки включают avg_daily_traded_value_20d, amihud_20d, spread_proxy и turnover_ratio. Эти показатели позволяют отличать риск, связанный с ценовой изменчивостью, от риска, связанного с

невозможностью эффективно совершить сделку. В финансовом анализе это различие важно, поскольку высоколиквидный волатильный актив и низколиквидный актив с редкими сделками имеют разные риск-профили.

Макроэкономические признаки включают `cbr_key_rate`, `usd_rub`, `ofz_slope_10y_2y`, `imoex_realized_vol_20d` и `average_market_correlation_60d`. На их основе формируется `regime_cluster`. Кластеризация обучается только на `train`-периоде, после чего присваивает режимы `validation` и `test`. Это предотвращает использование будущего распределения макроэкономических признаков.

Фундаментальные признаки рассчитываются из отчетных данных и включают `net_debt_to_ebitda`, `interest_coverage`, `free_cash_flow`, `ebitda_margin` и `book_to_market`. Дополнительно учитываются признаки пропусков, поскольку отсутствие отчетных данных само по себе может быть информационным сигналом. Например, неполная отчетность или большой лаг публикации повышают неопределенность оценки.

Для расширения признакового пространства используются производные признаки: `downside_to_total_vol`, `liquidity_stress`, `liquidity_vol_interaction`, `beta_vol_interaction`, `macro_pressure`, `rate_fx_pressure`, `debt_service_stress`, `cashflow_buffer`, `momentum_reversal_risk` и `fundamental_fragility`. Эти признаки не являются произвольными: каждый из них отражает экономически интерпретируемое взаимодействие факторов.

Целевая переменная строится по будущему окну 126 торговых дней. Для каждой пары акция-дата решения рассчитываются `future_max_drawdown`, `future_downside_volatility`, `future_cvar_95` и `future_illiquidity`. Затем `TargetRanker` переводит каждую компоненту в процентиль относительно `train`-периода и формирует итоговый `risk_score`.

Параметр целевой переменной	Значение
Горизонт будущего окна	126 торговых дней
Вес <code>future_max_drawdown</code>	0,35
Вес <code>future_downside_volatility</code>	0,30
Вес <code>future_cvar_95</code>	0,20
Вес <code>future_illiquidity</code>	0,15
Порог low/medium	0.3589
Порог medium/high	0.6331

При такой реализации целевая переменная не требует ручной экспертной разметки каждого наблюдения. Экспертная логика проявляется на уровне выбора компонент и весов, а сами классы рассчитываются воспроизводимо. Это снижает субъективность и позволяет повторить разметку при изменении исходных данных.

Важным результатом является контроль качества данных. В свежем запуске проверка показала отсутствие дубликатов по ключам `decision_date` и `ticker`, корректность дат и доступность целевых компонент примерно для 94,2% строк. Наблюдения без достаточного будущего окна исключаются из обучения, что предотвращает некорректные `target`-значения.

3.3. Реализация моделей машинного обучения

Модельная часть реализована как набор архитектур-кандидатов. Для каждой архитектуры обучается `candidate ensemble`, состоящий из Random Forest, Extra Trees и Gradient Boosting. Вероятности моделей выравниваются по каноническому порядку классов `low`, `medium`, `high`, после чего объединяются `soft-voting` ансамблем с весами, подобранными на `validation`.

После объединения вероятностей используется калибровка `power transform`. Она преобразует вероятности p в p^{γ} и нормирует их обратно. Если γ меньше единицы, распределение становится мягче; если больше единицы, вероятности становятся резче. γ выбирается по `validation`, что повышает согласованность вероятностей и итоговых решений.

`Probability policy` использует пороги для классов `low` и `high`. Это позволяет отдельно управлять чувствительностью к высокому риску, а не полагаться только на `argmax`. В задачах риск-менеджмента такой подход оправдан: пропуск класса `high` обычно опаснее, чем избыточное предупреждение.

Кластеризационный слой реализован через KMeans-like алгоритм на NumPy. Он обучается на макроэкономических признаках `train`-периода и формирует категориальный признак `regime_cluster`. В свежем запуске использовались два кластера режима. Смысл слоя состоит не в том, чтобы

получить окончательный класс риска, а в том, чтобы дать классификатору информацию о рыночном контексте.

Нейросетевой слой представлен классом `AutoencoderFactors`. Он обучается на числовых признаках `train`-периода и возвращает латентные факторы `latent_factor_*`. В рассматриваемом запуске использовался backend `torch_linear_autoencoder_pca_init`, что зафиксировано в `metrics.json`. Это означает, что латентные факторы получены через PyTorch `encoder/decoder`, инициализированный устойчивыми главными компонентами.

Отдельно реализован секторный `overlay`: он сравнивает глобальную модель и экспертную ветку по секторам на `validation` и включает секторного эксперта только при достаточном приросте. В свежем запуске секторные эксперты не были выбраны, то есть `overlay` не улучшил `validation` по заданному критерию. Это является важным ограничением и показывает, что усложнение архитектуры должно включаться только при подтвержденном приросте.

Архитектура	Состав признаков	Назначение
<code>baseline_rf</code>	рыночные, ликвидностные, макро признаки	Базовый метод сравнения
<code>regime_only</code>	<code>baseline + regime_cluster</code>	Проверка вклада кластеризации режимов
<code>enriched_reference</code>	<code>baseline +</code> фундаментальные и отчетные признаки	Проверка расширенного признакового пространства
<code>ann_plus_regime</code>	<code>enriched +</code> латентные факторы	Проверка вклада нейросетевого/факторного слоя
<code>sector_overlay</code>	выбор глобальной или экспертной ветки по сектору	Проверка секторной специализации

Модель	Val macro-F1	Val high recall	Test macro-F1	Test high recall
<code>baseline</code>	0.6573	0.8676	0.3416	0.7812
<code>regime</code>	0.6746	0.9118	0.2922	0.9062
<code>reports</code>	0.6848	0.8676	0.4069	0.8125
<code>ann+regime</code>	0.6903	0.8676	0.5494	0.9062
<code>overlay</code>	0.6848	0.8676	0.4069	0.8125

Из таблицы видно, что лучшей итоговой архитектурой в свежем запуске стала `ann_plus_regime`. На `test` она достигла `macro-F1` 0,5494 и `recall` высокого риска 0,9063. По сравнению с `baseline_rf` `macro-F1` увеличился с 0,3416 до

0,5494, а high false negative rate снизился с 0,2188 до 0,0938. Это подтверждает полезность гибридной архитектуры, но также показывает, что абсолютное качество остается ограниченным и требует дальнейшего улучшения данных и признаков.

3.4. Оценка качества и интерпретация результатов

Итоговой выбранной архитектурой стала `ann_plus_regime`. На тестовом периоде она показала $\text{macro-F1} = 0.5494$, $\text{weighted-F1} = 0.5413$, $\text{balanced accuracy} = 0.5714$, $\text{high recall} = 0.9062$, $\text{high precision} = 0.4143$.

Фактический класс	Pred low	Pred medium	Pred high
actual_low	7	2	7
actual_medium	0	20	34
actual_high	2	1	29

Класс	Precision	Recall	F1-score	Support
low	0.7778	0.4375	0.5600	16
medium	0.8696	0.3704	0.5195	54
high	0.4143	0.9062	0.5686	32

Матрица ошибок показывает сильную сторону модели: класс `high` обнаруживается с высоким `recall`. Это важно для риск-ориентированной задачи, где пропуск высокорискованного наблюдения может быть более критичным, чем избыточное предупреждение. Однако `precision` класса `high` остается умеренным, что означает наличие ложных срабатываний.

Класс `medium` является наиболее сложным для классификации. Это ожидаемо, поскольку средний риск расположен между `low` и `high` и часто содержит переходные состояния. Ошибки `medium` в сторону `high` могут быть приемлемы с консервативной точки зрения, но ошибки `high` в сторону `medium` или `low` требуют дополнительного контроля.

Сравнение архитектур показывает, что добавление режима само по себе повышает `high recall`, но снижает `macro-F1` на `test`. Расширенный отчетный слой улучшает `validation` и дает полезные признаки, но на `test` уступает

ann_plus_regime. Наиболее сильный результат дает сочетание расширенных признаков, режима и латентных факторов.

Walk-forward проверка показала 12 фолдов, средний макро-F1 около 0,2960 и средний high recall около 0,6506. Эти значения ниже итогового test-результата и указывают на нестабильность качества во времени. Для финансовой задачи это не является неожиданным: режимы рынка меняются, а распределения признаков подвержены дрейфу.

Диагностика дрейфа выявила значительное число предупреждений. Это означает, что распределения части признаков на validation и test отличаются от train-периода. В дипломе важно не скрывать этот факт, а использовать его как объяснение ограничений модели и как аргумент в пользу регулярного переобучения, мониторинга данных и расширения выборки.

Feature importance показывает, что среди важных признаков выделяются rate_fx_pressure, cbr_key_rate, log_market_cap_sector_z, log_market_cap, turnover_ratio, amihud_20d_sector_z, momentum_6m и average_market_correlation_60d. Это экономически интерпретируемый набор: модель учитывает процентно-валютный режим, размер компании, ликвидность, моментум и синхронность рынка.

Полученные результаты позволяют сделать осторожный вывод: гибридный подход действительно улучшает качество по сравнению с базовой моделью, особенно в части обнаружения высокого риска. Однако модель не является готовой промышленной системой. Ее качество зависит от полноты данных, устойчивости отчетного слоя, горизонта целевой переменной и изменения рыночного режима.

3.5. Оценка масштабируемости и воспроизводимости процесса

После оценки качества модели необходимо отдельно оценить сам процесс классификации. Это важно, потому что тема работы говорит об оптимизации процесса, а не только о выборе лучшего алгоритма. В рамках реализации процесс начинается с model-ready таблицы, проходит через расчет признаков,

target layer, обучение, выбор архитектуры, диагностику и завершается сохранением артефактов.

Масштабируемость подтверждается тем, что пайплайн работает с панелью наблюдений, где каждая строка соответствует паре акция-дата решения. Добавление новых дат или эмитентов не требует переписывать правила классификации вручную: при наличии данных код повторяет ту же последовательность операций. Это не делает процесс бесконечно масштабируемым, но устраняет линейное повторение ручных расчетов.

В свежем запуске входная таблица содержала 932 строки и 135 столбцов. После отбора наблюдений с доступным будущим окном использовались train, validation и test подвыборки. Такой масштаб не является промышленно большим, однако достаточен, чтобы показать переход от ручного анализа отдельных эмитентов к пакетной процедуре обработки панельных данных.

Воспроизводимость обеспечивается сохранением конфигурации и артефактов. Файл metrics.json содержит итоговые метрики, пороги target layer, распределение классов, выбранную архитектуру и диагностические показатели. Файл predictions.csv позволяет проверить каждое предсказание. Файл feature_importance.csv показывает вклад признаков. Run manifest фиксирует входные параметры и окружение запуска.

Отдельную роль играют тесты кодовой базы. Наличие тестов не доказывает абсолютную корректность исследования, но снижает риск грубых ошибок в компонентах пайплайна. Для дипломной работы это важно: если проверяются функции target layer, временного разбиения, feature engineering и evaluation, реализация выглядит как инженерно оформленный исследовательский проект, а не набор разрозненных скриптов.

Сравнение с ручным анализом следует формулировать аккуратно. Работа не измеряет время конкретного аналитика с секундомером, поэтому нельзя заявлять точный процент ускорения. Однако можно показать качественное отличие: ручная процедура требует повторения действий для каждого

наблюдения, а ML-пайплайн выполняет их пакетно и сохраняет единый журнал результата.

Прирост воспроизводимости также не выражается одной числовой метрикой. Он проявляется в том, что повторный запуск с теми же файлами и параметрами должен привести к тем же правилам обработки, тем же порогам и сопоставимым метрикам. В ручном анализе это трудно обеспечить, потому что часть решений часто остается в комментариях, таблицах или памяти аналитика.

Прирост точности оценивается численно. В свежем запуске гибридная архитектура `ann_plus_regime` превзошла `baseline_rf` по `macro-F1` и `balanced accuracy`, а также снизила долю пропущенных `high`-наблюдений. Именно эти показатели следует выносить на защиту как доказательство того, что усложнение архитектуры дало измеримый эффект.

Показатель	Baseline RF	Итоговая архитектура	Изменение
Macro-F1	0.3416	0.5494	0.2078
Balanced accuracy	0.4078	0.5714	0.1636
High recall	0.7812	0.9062	0.1250
High false negative rate	0.2188	0.0938	-0.1250

Изменение `high false negative rate` имеет особое значение. Для риск-классификации опаснее пропустить высокорисковый объект, чем ошибочно отнести умеренный риск к высокому. Поэтому снижение этого показателя можно трактовать как улучшение защитной функции процесса. Одновременно необходимо признать, что рост `recall` сопровождается умеренным `precision` класса `high`.

Масштабируемость, воспроизводимость и точность связаны между собой. Если процесс плохо воспроизводим, нельзя надежно сравнивать метрики. Если процесс не масштабируется, модель трудно применять к регулярной панели. Если модель не улучшает качество, автоматизация превращается только в ускорение расчетов. Разработанный пайплайн закрывает все три аспекта на уровне исследовательского прототипа.

Артефакты запуска также полезны для последующего развития работы. По `predictions.csv` можно анализировать ошибки по датам и тикерам. По `feature_importance.csv` можно уточнять признаки. По `drift report` можно решать, когда модель необходимо переобучить. Таким образом, пайплайн не заканчивается одной таблицей метрик, а создает основу для дальнейшего цикла улучшения.

3.6. Ограничения реализации и направления развития

Несмотря на полученный прирост качества, разработанную систему нельзя представлять как завершенное промышленное решение. Она является исследовательским прототипом, демонстрирующим методику автоматической классификации риска. У такого прототипа есть ограничения по данным, по устойчивости во времени, по полноте отчетного слоя и по интерпретации вероятностей.

Первое ограничение связано с размером выборки. Панель содержит ограниченное число эмитентов и месяцев, а классы риска формируются по будущему окну. Чем меньше наблюдений в каждом классе и периоде, тем сильнее метрики зависят от конкретного рыночного режима. Поэтому расширение `universe` эмитентов является естественным направлением развития.

Второе ограничение связано с периодом 2022-2026 годов. Этот интервал включает сильные изменения макроэкономической среды, ставок, валютного курса и режима раскрытия информации. С одной стороны, это полезно для проверки модели в стрессовых условиях. С другой стороны, распределения признаков заметно дрейфуют, поэтому качество, полученное на одном `test`-периоде, нельзя автоматически переносить на будущие годы.

Третье ограничение относится к отчетным признакам. Финансовая отчетность может быть неполной, опубликованной с лагом или извлеченной с ошибками. В реализации предусмотрены признаки качества извлечения и пропусков, но этого недостаточно для полного решения проблемы. В дальнейшем необходимо улучшить загрузку отчетности, унифицировать формы и добавить более строгую проверку `point-in-time` доступности.

Четвертое ограничение связано с нейросетевым слоем. В актуальном запуске используется PyTorch autoencoder backend с PCA-инициализацией линейного bottleneck слоя. Это не следует подавать как глубокую end-to-end нейросеть: корректнее говорить о нейросетевом извлечении компактных латентных факторов, которое затем усиливает интерпретируемый ансамбль деревьев.

Пятое ограничение связано с выбором весов risk_score. Веса 0,35, 0,30, 0,20 и 0,15 имеют экономическое обоснование, но не являются единственно возможными. В дальнейшем их можно подбирать через отдельную процедуру: экспертную калибровку, устойчивость метрик, сравнение горизонтов или оптимизацию по экономической функции потерь.

Шестое ограничение относится к вероятностям. Даже если класс выбран правильно, вероятность может быть плохо откалибрована. Для практического риск-скоринга важно не только назвать класс, но и понимать степень уверенности. В текущей реализации используется калибровка power transform, однако в дальнейшем можно сравнить Platt scaling, isotonic calibration и более строгую out-of-time калибровку.

Седьмое ограничение связано с интерпретацией ошибок. Модель хорошо обнаруживает high, но дает ложные предупреждения. Для риск-ориентированной системы это может быть приемлемо, но для инвестиционного отбора требуется баланс между предупреждением и избыточным исключением активов. Поэтому следующие версии должны анализировать не только F1-score, но и экономические последствия ошибок.

Практическое развитие пайплайна может идти в нескольких направлениях. Во-первых, расширение данных: больше эмитентов, больше истории, корпоративные события, дивиденды и новости. Во-вторых, усиление признаков: отраслевые факторы, кредитные спреды, показатели раскрытия, календарь отчетности. В-третьих, развитие моделей: более строгая калибровка, stacked ensemble, temporal cross-validation и мониторинг дрейфа.

Методическое развитие работы может включать сравнение нескольких target-конструкций. Например, можно проверить отдельно target на основе просадки, target на основе CVaR и комбинированный target. Если комбинированный target устойчивее, это усилит обоснование выбранной постановки. Если отдельная компонента окажется лучше, это позволит уточнить экономическую интерпретацию риска.

Еще одно направление - анализ чувствительности к горизонту будущего окна. Горизонт 126 торговых дней разумен для полугодовой оценки, но для разных инвесторов могут быть важны месячный, квартальный или годовой горизонты. Проверка нескольких горизонтов позволит понять, насколько модель классифицирует краткосрочный стресс или более долгосрочную уязвимость актива.

Важным направлением остается объяснимость. Feature importance дает общий список сильных признаков, но не объясняет каждое отдельное решение. Для дальнейшей работы можно добавить SHAP-значения, локальные объяснения по тикеру и дате, а также отчеты, где высокий риск раскладывается на рыночную, ликвидностную, макроэкономическую и фундаментальную составляющие.

Наконец, систему можно развить до регулярного процесса мониторинга. Такой процесс должен включать обновление данных, расчет новых признаков, проверку дрейфа, переобучение по расписанию, сохранение версий модели и выпуск отчета по изменениям классов риска. Именно в таком виде тема оптимизации процесса будет раскрыта максимально полно.

Ограничение	Проявление	Направление доработки
Размер выборки	Ограниченное число эмитентов и месяцев	Расширить universe и исторический период
Дрейф рынка	Изменение распределений между train и test	Добавить мониторинг PSI и регулярное переобучение
Отчетность	Лаги, пропуски и неоднородное раскрытие	Усилить point-in-time слой и контроль качества
Латентные факторы	PyTorch linear autoencoder с PCA-инициализацией	Проверять нелинейные варианты только через validation ablation

Калибровка	Умеренная precision класса high	Проверить альтернативные калибраторы и пороги
Интерпретация	Общие importance без локального объяснения	Добавить SHAP и decomposition отчеты

3.7. Экономическая интерпретация результатов классификации

Формальные метрики показывают качество классификации, но для диплома по инвестиционным рискам этого недостаточно. Необходимо объяснить, почему полученные классы имеют экономический смысл. Иначе работа может выглядеть как техническое сравнение алгоритмов, оторванное от предметной области.

Первый уровень интерпретации связан с матрицей ошибок. Модель чаще относит наблюдения среднего риска к high, чем фактические high к low. Для риск-ориентированной задачи такая асимметрия в целом приемлема: избыточное предупреждение менее опасно, чем пропуск высокорискового состояния. Однако это также показывает, что модель консервативна и может завышать риск для пограничных наблюдений.

Второй уровень интерпретации связан с классом medium. Средний риск является естественно сложным классом, потому что он расположен между устойчивыми и стрессовыми состояниями. В финансовых данных граница между medium и high часто зависит от режима рынка: при спокойной макросреде тот же уровень ликвидности может быть приемлемым, а при росте ставки и корреляции рынка - проблемным.

Третий уровень интерпретации связан с feature importance. Если среди важных признаков присутствуют только технические идентификаторы или случайные поля, модель нельзя считать предметно надежной. В свежем запуске среди значимых признаков выделяются rate_fx_pressure, cbr_key_rate, log_market_cap, turnover_ratio, amihud_20d_sector_z, momentum_6m и average_market_correlation_60d. Такой набор согласуется с экономической логикой риска.

Признак `cbr_key_rate` отражает стоимость капитала и давление на долговые компании. При высокой ставке стоимость рефинансирования возрастает, а оценка будущих денежных потоков снижается. Поэтому присутствие ставки среди важных признаков показывает, что модель учитывает внешний макроэкономический режим, а не только прошлую цену акции.

`Rate_fx_pressure` соединяет процентную и валютную составляющие. Для российского рынка такая комбинация особенно значима: изменение курса и ставки влияет на импортные издержки, экспортную выручку, долговую нагрузку и ожидания инвесторов. Важность этого признака показывает, что модель реагирует на состояние среды, в которой торгуется эмитент.

`Log_market_cap` и его секторные преобразования отражают размер компании. Крупные эмитенты обычно имеют более высокую ликвидность, большую аналитическую покрытость и более устойчивый доступ к капиталу. Малые компании могут быть более чувствительны к отдельным сделкам и корпоративным событиям. Поэтому размер компании является экономически оправданным фактором риска.

`Turnover_ratio` и `amihud_20d_sector_z` описывают ликвидностную сторону риска. Даже если цена актива исторически была стабильной, низкая ликвидность может усилить потери в стрессовый период. Высокая важность ликвидностных признаков подтверждает, что модель оценивает не только волатильность, но и способность рынка поглотить сделки.

`Momentum_6m` отражает предшествующее направление движения цены. Его влияние может быть неоднозначным: устойчивый рост иногда связан с сильным спросом, но резкое движение может предшествовать коррекции. Деревья решений полезны именно потому, что могут учитывать momentum не линейно, а в сочетании с волатильностью, ликвидностью и макрофоном.

`Average_market_correlation_60d` описывает степень синхронности рынка. В периоды стресса корреляции между активами часто растут, и диверсификация работает хуже. Если модель учитывает этот показатель, она

получает информацию о системном режиме, а не только об индивидуальных свойствах эмитента.

Экономическая монотонность классов является отдельной проверкой результата. В свежем запуске средние значения `future_max_drawdown` и `future_cvar_95` увеличиваются от low к high. Это означает, что предсказанные классы упорядочены по двум ключевым риск-компонентам: глубине просадки и хвостовой потере. Такой результат поддерживает интерпретацию классов как уровней риска.

При этом `downside-volatility` и `future_illiquidity` не демонстрируют полной монотонности. Это важное наблюдение, которое не следует скрывать. Оно показывает, что итоговый класс определяется несколькими компонентами, а отдельные компоненты могут вести себя неодинаково. Например, high-класс может быть вызван глубокой просадкой и CVaR, даже если будущая неликвидность не является максимальной.

С точки зрения риск-менеджмента это означает, что итоговый класс следует трактовать как агрегированную категорию, а не как утверждение о росте каждой отдельной риск-метрики. Такой вывод согласуется с конструкцией `risk_score`: он объединяет несколько компонент с разными весами, поэтому монотонность по всем компонентам одновременно не гарантируется.

Отдельно важно интерпретировать снижение high false negative rate. Если baseline пропускает больше высокорисковых наблюдений, он менее пригоден для защитной классификации. Итоговая архитектура уменьшает число таких пропусков, что является содержательным улучшением процесса. При этом рост предупреждений high требует дальнейшей настройки порогов под конкретный профиль допустимого риска.

Walk-forward результаты показывают, что качество не является равномерным во времени. Это экономически объяснимо: рынок проходит через разные режимы, и связь между признаками и будущими потерями меняется.

Поэтому модель следует использовать с мониторингом, а не как статичное правило, однажды обученное на всей истории.

Диагностика дрейфа усиливает этот вывод. Если распределение ставки, валютного курса, ликвидности или рыночной корреляции заметно меняется, правила, выученные на train, могут хуже работать на будущих периодах. В практическом контуре это означает необходимость регулярного переобучения и контроля стабильности признаков.

Интерпретация результатов также помогает объяснить, почему в работе объединяются несколько методов. Деревья решений дают интерпретируемые разбиения и importance. Кластеризация добавляет рыночный режим, позволяя одной и той же характеристике иметь разный смысл в разных условиях. Латентные факторы обобщают многомерное признаковое пространство, снижая зависимость модели от отдельных шумных переменных.

Таким образом, результат классификации можно защищать по двум линиям. Первая линия - статистическая: прирост macro-F1, balanced accuracy и high recall относительно baseline. Вторая линия - экономическая: важные признаки и монотонность ключевых риск-компонент соответствуют логике инвестиционного риска. Вместе эти линии делают вывод работы более убедительным.

Важно также отметить, что экономическая интерпретация не заменяет метрики. Если модель звучит правдоподобно, но плохо работает на test, ее нельзя считать успешной. И наоборот, если метрики выросли, но признаки и классы не имеют предметного смысла, результат трудно защитить. В данной работе обе части используются совместно.

Предсказанный класс	Future MDD	Future CVaR 95%	Future downside vol	Future illiquidity
low	0.1659	0.0328	0.0112	0.00000000
medium	0.1837	0.0353	0.0109	0.00000000
high	0.2269	0.0399	0.0122	0.00000000

Вывод по разделу 3.7: итоговая модель дает не только численный прирост качества, но и экономически интерпретируемый результат. Классы high

связаны с более высокой просадкой и хвостовой потерей, а важные признаки отражают процентно-валютный режим, размер компании, ликвидность, momentum и рыночную синхронность.

3.8. Последовательность применения разработанного процесса

Разработанный процесс можно представить как последовательность действий, которую исследователь выполняет при обновлении классификации. Такая последовательность важна для воспроизводимости: она показывает, какие операции должны быть выполнены до обучения, какие - во время выбора модели, а какие - после получения результатов.

Первый этап состоит в обновлении исходных данных. Для каждого тикера должны быть доступны цены, объемы торгов, денежный оборот, рыночный индекс, макроэкономические ряды и отчетные признаки. На этом этапе проверяется наличие дат, корректность типов данных и отсутствие дубликатов по ключам. Если данные неполные, это фиксируется до обучения модели.

Второй этап - формирование месячных срезов. Дневные данные агрегируются в признаки, доступные на дату решения. Скользящие окна рассчитываются только по прошлым наблюдениям, поэтому текущая строка не должна использовать будущие цены. Этот этап является техническим, но именно здесь часто возникают ошибки временной логики.

Третий этап - присоединение макроэкономических и отчетных данных. Макроэкономические признаки должны соответствовать состоянию среды на дату решения. Отчетность присоединяется по дате публикации, а не по периоду отчета. Если отчет опубликован позже, он не может использоваться для более раннего решения.

Четвертый этап - расчет производных признаков. На этом этапе формируются liquidity_stress, macro_pressure, rate_fx_pressure, beta_vol_interaction, debt_service_stress и другие показатели. Их задача состоит в том, чтобы перевести экономические взаимодействия в числовые признаки, пригодные для модели.

Пятый этап - построение target layer. Для каждого наблюдения рассчитывается будущая реализация риска по окну 126 торговых дней. Наблюдения без полного будущего окна исключаются из обучения и оценки. Затем компоненты переводятся в train-процентили, объединяются в risk_score и превращаются в классы low, medium и high.

Шестой этап - временное разделение выборки. Train используется для обучения preprocessing, target-порогов, кластеров и моделей. Validation используется для выбора архитектуры, калибровки вероятностей и настройки policy. Test остается финальной проверкой. Такая дисциплина отделяет разработку модели от оценки результата.

Седьмой этап - обучение модельных ветвей. Сначала строится baseline, затем проверяются варианты с режимами, отчетными признаками, латентными факторами и секторным overlay. Каждый вариант оценивается одинаковыми метриками, что позволяет сравнивать архитектуры не по описанию, а по результату.

Восьмой этап - выбор итоговой архитектуры. Выбор не должен выполняться вручную после просмотра test. В работе он основан на validation-критерии, который учитывает macro-F1 и способность находить высокий риск. Test используется только после выбора, чтобы получить честную оценку качества.

Девятый этап - интерпретация. После получения метрик необходимо рассмотреть матрицу ошибок, classwise precision и recall, feature importance, экономическую монотонность и drift report. Без этой интерпретации невозможно понять, почему модель ошибается и какие компоненты процесса требуют доработки.

Десятый этап - сохранение результатов. Метрики, предсказания, важности признаков, отчеты о дрейфе и model package должны храниться в отдельной директории запуска. Это позволяет позже восстановить, какие данные и параметры использовались, и сравнить новый запуск с предыдущим.

Такая последовательность отличает разработанный процесс от ручной классификации. В ручном подходе многие действия могут выполняться в произвольном порядке и оставаться незафиксированными. В ML-пайплайне порядок операций задан явно, а результат каждого этапа может быть проверен.

Последовательность также показывает, какие элементы являются обязательными для переноса процесса на новые данные. Нельзя просто обучить модель на обновленной таблице: необходимо заново проверить point-in-time логику, пересчитать target-пороги только на train, оценить дрейф и убедиться, что новые признаки не нарушают структуру входного пространства.

С практической точки зрения разработанный процесс может использоваться как исследовательский шаблон. Если добавляется новый источник данных, его нужно встроить в этап признаков и проверить на leakage. Если меняется горизонт риска, нужно пересчитать target layer и сравнить метрики. Если появляется новая модель, ее нужно включить в leaderboard и оценить на тех же временных разбиениях.

Именно такая воспроизводимая последовательность позволяет говорить об оптимизации процесса. Улучшение состоит не только в том, что итоговая модель показала более высокий macro-F1, но и в том, что весь путь от данных до вывода стал формализованным, проверяемым и расширяемым.

После каждого нового запуска необходимо анализировать не только итоговую строку leaderboard. Сначала проверяется, не изменилось ли распределение классов и достаточно ли наблюдений в каждом классе. Затем рассматриваются изменения порогов target layer. Если пороги резко сместились, это может указывать на изменение рыночной среды или на проблему в данных.

Следующий шаг проверки - анализ предсказаний по конкретным объектам. Для каждого наблюдения доступны дата, тикер, фактический класс и предсказание. Это позволяет находить не только средние ошибки, но и повторяющиеся проблемные случаи: отдельные эмитенты, сектора или периоды, где модель систематически завышает или занижает риск.

Feature importance используется как контроль предметной разумности нового запуска. Если среди лидирующих признаков внезапно появляются технические поля или признаки с сомнительным экономическим смыслом, результат требует проверки. Если же важные признаки устойчиво связаны с макроэкономическим режимом, ликвидностью, размером компании и рыночной динамикой, модель легче интерпретировать.

Drift report должен рассматриваться как сигнал к переобучению или пересмотру признаков. Высокий дрейф не означает автоматическую ошибку модели, но показывает, что условия применения отличаются от train-периода. Для финансового рынка это особенно важно: модель, обученная в одном режиме ставок и ликвидности, может хуже работать в другом режиме.

Таким образом, применение пайплайна включает не только запуск команды обучения, но и исследовательскую проверку результата. Пользователь процесса должен пройти по цепочке: качество данных, target-пороги, leaderboard, test-метрики, матрица ошибок, importance, drift и экономическая интерпретация. Только после этого классификацию можно считать корректно полученной.

Этап процесса	Вход	Выход	Контроль
Обновление данных	raw prices, macro, reports	исходные таблицы	ключи, даты, пропуски
Расчет признаков	исторические данные	feature matrix	point-in-time доступность
Target layer	будущие окна	risk_score и классы	train-only пороги
Разбиение	model-ready panel	train/validation/test	временной порядок
Обучение моделей	train и validation	leaderboard	единые метрики
Финальная оценка	test	metrics и predictions	матрица ошибок
Интерпретация	importance, drift, monotonicity	выводы и ограничения	экономический смысл

Вывод по разделу 3.8: разработанный пайплайн является не только моделью, но и последовательным исследовательским процессом. Его можно повторять, расширять и проверять, что напрямую соответствует цели оптимизации автоматической классификации инвестиционных рисков.

С учетом этих ограничений результат работы следует формулировать как успешную разработку и проверку исследовательского ML-пайплайна. Он демонстрирует, что объединение деревьев решений, кластеризационного анализа и латентных факторов способно улучшить автоматическую классификацию инвестиционного риска относительно базовой модели.

Главный итог третьей главы состоит не в том, что получена идеальная модель, а в том, что реализован проверяемый процесс. В этом процессе экономические формулы переходят в признаки и target, признаки переходят в модельные ветви, модели сравниваются на validation, а итог проверяется на test и walk-forward. Такая последовательность делает работу логичной и защищаемой.

Вывод по третьей главе: реализован ML-пайплайн, в котором формулы и метрики, обоснованные во второй главе, применены для расчета признаков, формирования целевой переменной, обучения гибридных моделей и оценки качества. Лучшая архитектура в свежем запуске показала прирост относительно baseline, а анализ ограничений определил направления дальнейшего улучшения.

ЗАКЛЮЧЕНИЕ

В результате выполнения выпускной квалификационной работы была достигнута поставленная цель: разработан и оценен процесс автоматической классификации инвестиционных рисков путем объединения деревьев решений и кластеризационного анализа с использованием искусственных нейронных сетей.

В первой главе была сформулирована постановка задачи и обоснована актуальность автоматизации. Показано, что ручной и экспертный анализ инвестиционных рисков обладает важной предметной ценностью, но ограничен субъективностью, трудоемкостью, низкой воспроизводимостью и слабой масштабируемостью. Это обосновывает необходимость формализованного ML-пайплайна.

Во второй главе проведен анализ предметной области классификации инвестиционных рисков. Рассмотрены рыночные, ликвидностные, макроэкономические и фундаментальные аспекты риска. Обоснован выбор данных и формул, включая доходность, волатильность, downside-volatility, максимальную просадку, VaR, CVaR, Amihud illiquidity и beta. Эти показатели связали экономическую постановку задачи с программной реализацией.

В третьей главе описана реализация пайплайна на Python. Реализованы расчет признаков, формирование целевой переменной по будущему окну, временное train/validation/test разбиение, кластеризация рыночных режимов, ансамбли деревьев решений, слой латентных факторов и оценка качества. Проведена проверка на свежем запуске пайплайна.

Полученные результаты показывают, что гибридная архитектура `ann_plus_regime` превосходит базовую модель по `test macro-F1` и сохраняет высокий `recall` класса `high`. Это подтверждает применимость объединения деревьев решений, кластеризационного анализа и нейросетевого/факторного слоя к задаче автоматической классификации инвестиционного риска.

Вместе с тем результаты следует интерпретировать осторожно. Walk-forward проверка и диагностика дрейфа показывают, что качество модели

нестабильно во времени, а распределения признаков меняются между периодами. Поэтому разработанный пайплайн следует рассматривать как исследовательский прототип, требующий дальнейшего расширения данных, регулярного мониторинга и доработки отчетного слоя.

Научная новизна работы заключается в формализации многокомпонентной целевой переменной инвестиционного риска и в построении гибридного процесса классификации, где кластеризация используется для выделения рыночного режима, дерева решений - для интерпретируемой классификации, а нейросетевой слой - для извлечения скрытых факторов.

Практическая значимость состоит в том, что разработанный код сохраняет артефакты запуска, метрики, модельный пакет и диагностические отчеты. Это повышает воспроизводимость исследования и позволяет использовать проект как основу для дальнейшей системы риск-скоринга акций.

Дальнейшее развитие работы может включать расширение universe эмитентов, улучшение качества финансовой отчетности, добавление корпоративных событий, более строгую настройку весов целевой переменной, проверку других горизонтов риска и использование более устойчивых методов калибровки вероятностей.

Таким образом, поставленные задачи выполнены: изучены подходы к оценке инвестиционных рисков, выявлены ограничения ручного анализа, определены признаки и метрики, спроектирован и реализован ML-пайплайн, проведена оценка качества и сформулированы ограничения разработанного подхода.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. ГОСТ 7.32-2017. Система стандартов по информации, библиотечному и издательскому делу. Отчет о научно-исследовательской работе. Структура и правила оформления.
2. ГОСТ Р 7.0.100-2018. Система стандартов по информации, библиотечному и издательскому делу. Библиографическая запись. Библиографическое описание.
3. Марковиц Г. Выбор портфеля: эффективная диверсификация инвестиций. - М.: Альпина Паблишер, 2020.
4. Sharpe W. F. Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk // Journal of Finance. - 1964. - Vol. 19, No. 3. - P. 425-442.
5. Fama E. F., French K. R. The Cross-Section of Expected Stock Returns // Journal of Finance. - 1992. - Vol. 47, No. 2. - P. 427-465.
6. Jorion P. Value at Risk: The New Benchmark for Managing Financial Risk. - New York: McGraw-Hill, 2007.
7. Hull J. C. Risk Management and Financial Institutions. - Hoboken: Wiley, 2018.
8. McNeil A. J., Frey R., Embrechts P. Quantitative Risk Management: Concepts, Techniques and Tools. - Princeton: Princeton University Press, 2015.
9. Tsay R. S. Analysis of Financial Time Series. - Hoboken: Wiley, 2010.
10. Campbell J. Y., Lo A. W., MacKinlay A. C. The Econometrics of Financial Markets. - Princeton: Princeton University Press, 1997.
11. Amihud Y. Illiquidity and Stock Returns: Cross-section and Time-series Effects // Journal of Financial Markets. - 2002. - Vol. 5, No. 1. - P. 31-56.
12. Brealey R. A., Myers S. C., Allen F. Principles of Corporate Finance. - New York: McGraw-Hill, 2020.
13. Damodaran A. Investment Valuation: Tools and Techniques for Determining the Value of Any Asset. - Hoboken: Wiley, 2012.
14. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning. - New York: Springer, 2009.

15. Bishop C. M. Pattern Recognition and Machine Learning. - New York: Springer, 2006.
16. Goodfellow I., Bengio Y., Courville A. Deep Learning. - Cambridge: MIT Press, 2016.
17. Murphy K. P. Probabilistic Machine Learning: An Introduction. - Cambridge: MIT Press, 2022.
18. Breiman L. Random Forests // Machine Learning. - 2001. - Vol. 45. - P. 5-32.
19. Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // Annals of Statistics. - 2001. - Vol. 29, No. 5. - P. 1189-1232.
20. Géron A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. - Sebastopol: O'Reilly Media, 2022.
21. Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. - 2011. - Vol. 12. - P. 2825-2830.
22. Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. - 2019.
23. Московская Биржа. Программный интерфейс ISS. URL: <https://www.moex.com/a2193> (дата обращения: 16.05.2026).
24. Банк России. Официальный сайт. URL: <https://www.cbr.ru/> (дата обращения: 16.05.2026).
25. Документация pandas. URL: <https://pandas.pydata.org/docs/> (дата обращения: 16.05.2026).
26. Документация NumPy. URL: <https://numpy.org/doc/> (дата обращения: 16.05.2026).
27. Документация scikit-learn. URL: <https://scikit-learn.org/stable/> (дата обращения: 16.05.2026).
28. Документация PyTorch. URL: <https://pytorch.org/docs/stable/> (дата обращения: 16.05.2026).

29. Исходный код проекта risk_pipeline: локальный репозиторий выпускной квалификационной работы.
30. Результаты запуска пайплайна: локальная директория results/defense_run_architected.